Шпаргалка: SVM dual (двойственная постановка)

Идея. Условие $y_i(\mathbf{w}\cdot x_i + b) \geq 1$ встраиваем в функцию множителями $a_i \geq 0$ (по одному на точку), выражаем $\mathbf{w}$ через a и решаем задачу только про a. Чтобы терпеть нарушения (классы пересекаются), добавляем штраф C: он ограничивает вес каждой точки сверху.

1. Откуда задача про a

$$L(\mathbf{w}, b, a) = \tfrac{1}{2}\|\mathbf{w}\|^2 - \sum_i a_i\big(y_i(\mathbf{w}\cdot x_i + b) - 1\big), \qquad a_i \geq 0$$

Производная	Результат
$\partial L/\partial \mathbf{w} = 0$	$\mathbf{w} = \sum_i a_i y_i x_i$ (подставляем обратно в L)
$\partial L/\partial b = 0$	$\sum_i a_i y_i = 0$ (ограничение на a)

$$\max_a \sum_i a_i - \tfrac{1}{2}\sum_i\sum_j a_i a_j\, y_i y_j\, (x_i \cdot x_j) \qquad \text{при} \quad 0 \leq a_i \leq C,\ \sum_i a_i y_i = 0$$

Мягкий зазор. Разрешаем $y_i f(x_i) \geq 1 - \xi_i$ и минимизируем $\frac{1}{2}\|\mathbf{w}\|^2 + C\sum \xi_i$. Из $\partial L/\partial \xi_i = 0$ получается $a_i \leq C$. Большое C: зазор уже, нарушений меньше ($C = \infty$ — hard margin). Маленькое C: зазор шире, нарушения терпим.

KKT: $a_i = 0$: точка в порядке. $0 < a_i < C$: ровно на границе ($y_i f = 1$). $a_i = C$: нарушитель ($y_i f \leq 1$). Данные входят через $x_i \cdot x_j$, поэтому можно подставлять ядра.

2. Шаг SMO по паре $(i,\ j)$

Меняем сразу два числа: условие $\sum a_i y_i = 0$ не позволяет менять одно.

$$f(x_k) = \sum_t a_t y_t\,(x_t \cdot x_k) + b, \qquad E_k = f(x_k) - y_k, \qquad \eta = x_i\cdot x_i + x_j \cdot x_j - 2\,x_i \cdot x_j$$

$$a_j^{\text{нов}} = a_j + \frac{y_j\,(E_i - E_j)}{\eta}, \qquad a_i^{\text{нов}} = a_i + y_i y_j\,(a_j - a_j^{\text{нов}})$$

Метки	$a_j^{\text{нов}}$ обрезаем до
$y_i = y_j$	$\max(0,\ a_i + a_j - C) \leq a_j^{\text{нов}} \leq \min(C,\ a_i + a_j)$
$y_i \neq y_j$	$\max(0,\ a_j - a_i) \leq a_j^{\text{нов}} \leq \min(C,\ C + a_j - a_i)$

$$b_1 = b - E_i - y_i\Delta a_i\,(x_i\cdot x_i) - y_j\Delta a_j\,(x_i\cdot x_j), \qquad b_2 = b - E_j - y_i\Delta a_i\,(x_i\cdot x_j) - y_j\Delta a_j\,(x_j\cdot x_j)$$

$b = b_1$, если $0 < a_i^{\text{нов}} < C$; иначе $b = b_2$, если $0 < a_j^{\text{нов}} < C$; иначе $b = (b_1 + b_2)/2$. Здесь $\Delta a = a^{\text{нов}} - a$. Если бы a не менялись, хватило бы $b - E_i$; но новые a тоже сдвинули оценку на Δf (два слагаемых с Δa в b_1), и его тоже вычитаем.

3. Последовательность операций

```
1. a = [0, ..., 0],  b = 0
2. повторять, пока что-то меняется:
      для каждой точки i:
         E_i = f(x_i) - y_i
         если (y_i*E_i < -eps и a_i < C)  или  (y_i*E_i > eps и a_i > 0):
            j = точка (j != i) с наибольшим |E_i - E_j|;  E_j = f(x_j) - y_j
            eta = x_i·x_i + x_j·x_j - 2 x_i·x_j
            a_j_нов = a_j + y_j (E_i - E_j) / eta,  обрезать по таблице (с C)
            a_i_нов = a_i + y_i y_j (a_j - a_j_нов)
            пересчитать b (b1, b2),  записать a_i, a_j
3. w = сумма a_i y_i x_i
4. b = среднее по точкам с 0 < a_s < C от (y_s - w·x_s)
```

Предсказание: $\text{оценка} = \sum_i a_i y_i\,(x_i \cdot x) + b$, $\text{класс} = \text{sign}(\text{оценка})$.

4. Что помнить

- Шаг по паре: если ошибки E_i и E_j одинаковые, то a_j не меняется. Чем дальше точки друг от друга (больше η), тем шаг меньше.
- $\eta = 0$ (точки совпадают): пару пропускаем.
- Точка нарушает KKT, если $y_i E_i < -\varepsilon$ при $a_i < C$, либо $y_i E_i > \varepsilon$ при $a_i > 0$. Нарушителей нет — решение найдено.
- Второе число пары: с наибольшим $|E_i - E_j|$ (если пара не сработала, берём следующую). Случайный выбор тоже работает, но медленнее.
- C в dual — потолок веса точки. Связь с primal из `primal_svm.py`: $C_{\text{dual}} = C_{\text{primal}}/(2N)$.
- Dual удобен, когда признаков много или нужны ядра. Primal быстрее, когда признаков немного.