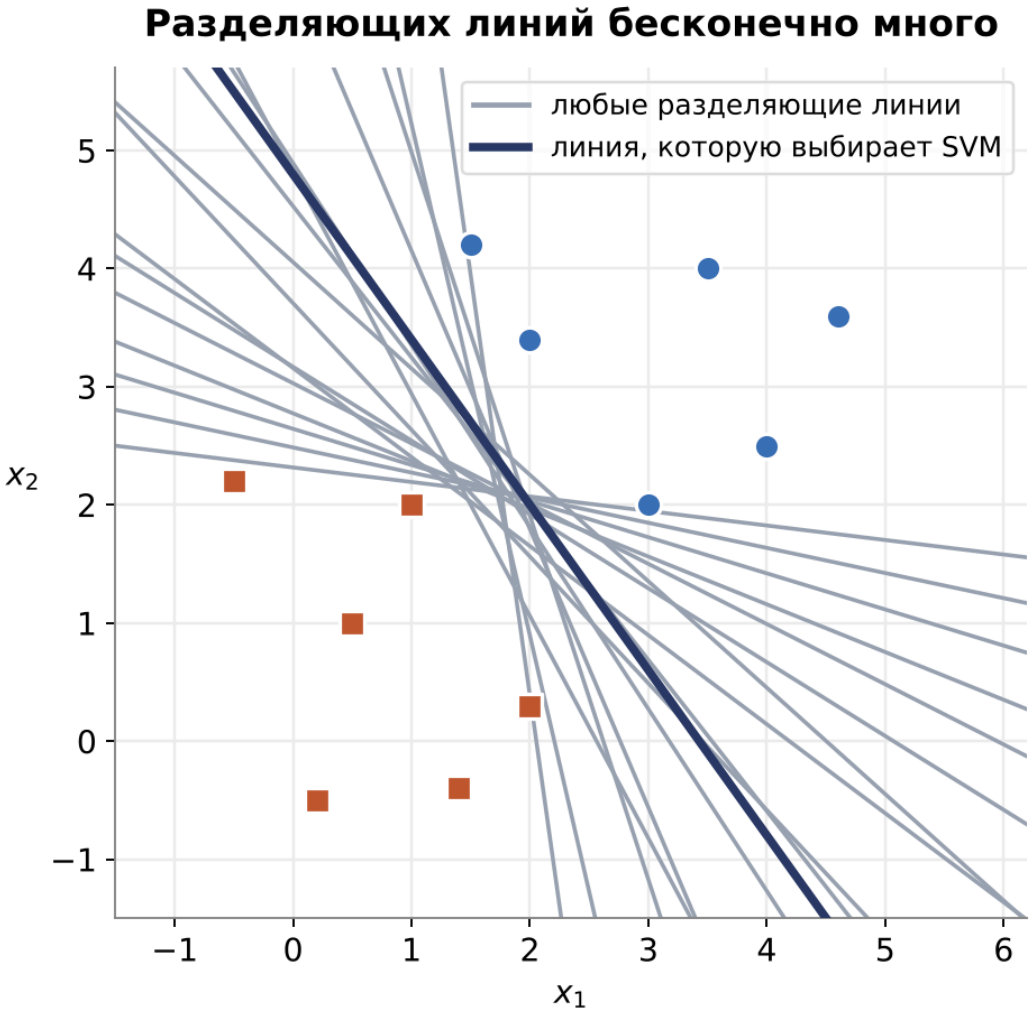
SVM. Часть 1. Введение: геометрия и постановка задачи

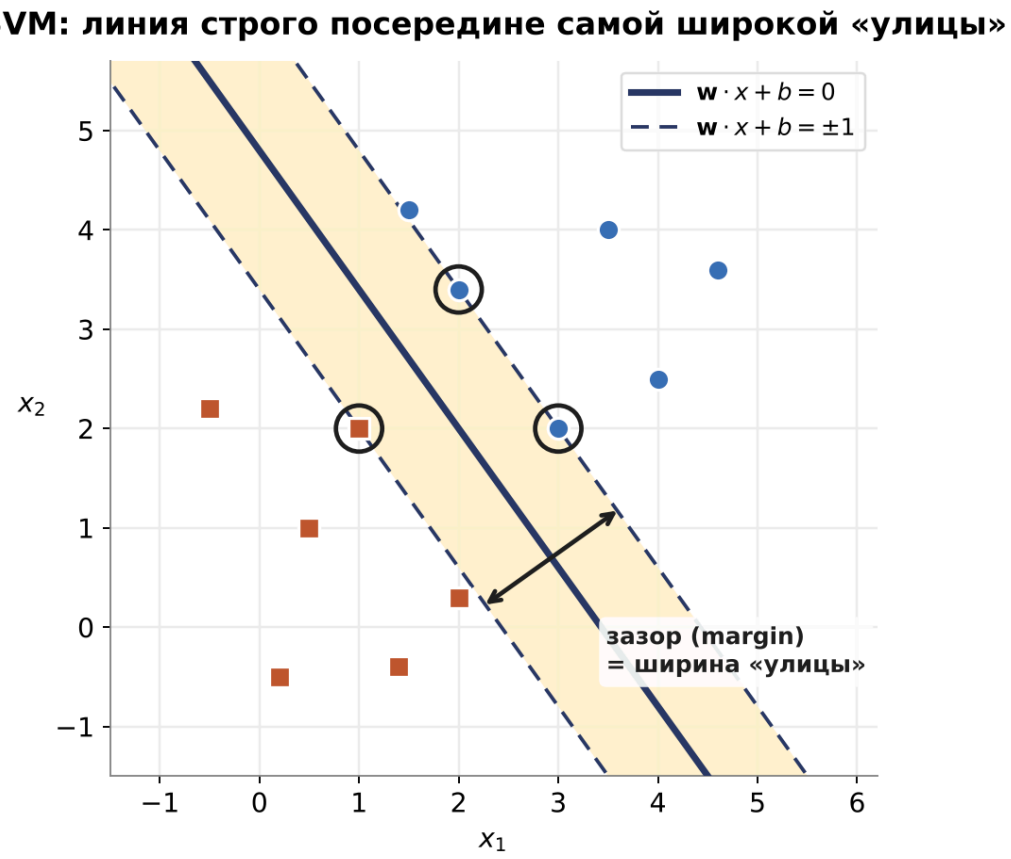
0. Постановка задачи

0.1. В чём задача

У нас есть точки двух классов (на графиках: синие круги и красные квадраты), и мы хотим провести прямую (в 2D) или плоскость (в многомерном пространстве это называется гиперплоскость), которая их разделит.



Проблема в том, что таких разделяющих линий бесконечно много. SVM выбирает ту, которая **максимально далеко отстоит от обоих классов**, то есть проводит линию строго посередине самой широкой «улицы», которую можно провести между классами. Эта улица называется **margin** (зазор). Чем шире зазор, тем устойчивее решение к шуму и новым данным.



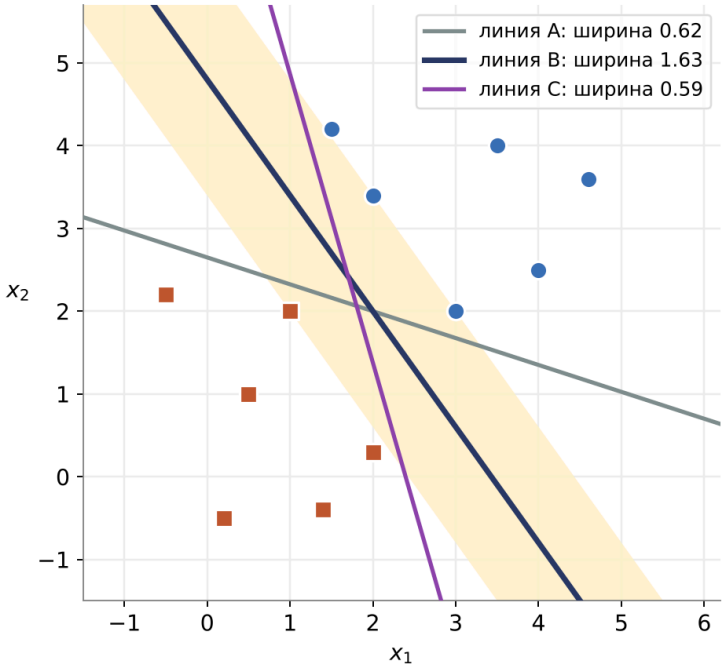
Пунктирные линии на графике — границы улицы. Что они значат и откуда берутся числа ± 1, разберём в шаге 4.

0.2. Зачем нужен зазор

Нам мало просто разделить имеющиеся данные: нужно, чтобы линия хорошо определяла классы и на **новых** данных тоже.

На графике ниже все три линии правильно делят обучающие точки. Но больше доверия внушает линия B: вокруг неё самая широкая полоса, в которой нет ни одной точки. У узких линий A и C новая точка рядом с границей легко окажется не по ту сторону.

Все три линии делят данные, но доверия они вызывают по-разному



Для этого и появляется параметр **ширина**, который нужно максимизировать.

Расстояние (ширина) считается по **опорным векторам**. Опорный вектор — это один или несколько элементов выборки, которые находятся к разделяющей прямой ближе всего. На графике «улицы» выше они обведены кружком. Подробно о них будет в шаге 4.1.

0.3. Уравнение гиперплоскости

Гиперплоскость задаётся так:

$$\mathbf{w} \cdot \mathbf{x} + b = 0$$

где $\mathbf{w}$ — вектор весов (нормаль к плоскости, то есть он перпендикулярен ей), $\mathbf{x}$ — точка, b — смещение (bias).

Все примеры дальше считаем на одной и той же линии:

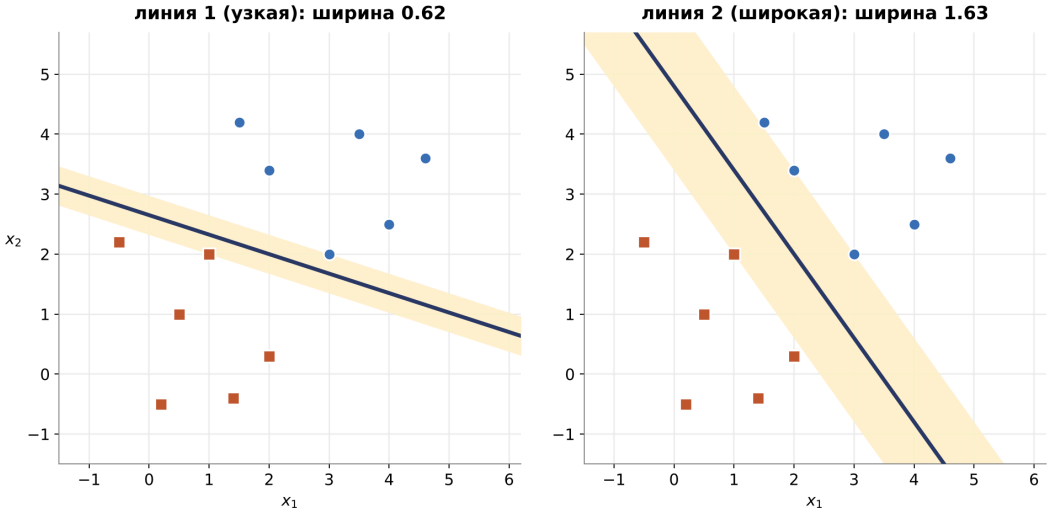
$$3x_1 + 5x_2 + 2 = 0$$

Здесь $\mathbf{w} = (3,\, 5)$, $\mathbf{x} = (x_1,\, x_2)$, $b = 2$. В двух измерениях гиперплоскость — это просто линия.

Вопрос: почему $\mathbf{w}$ перпендикулярен плоскости? Ответ в шагах 1 и 2 ниже.

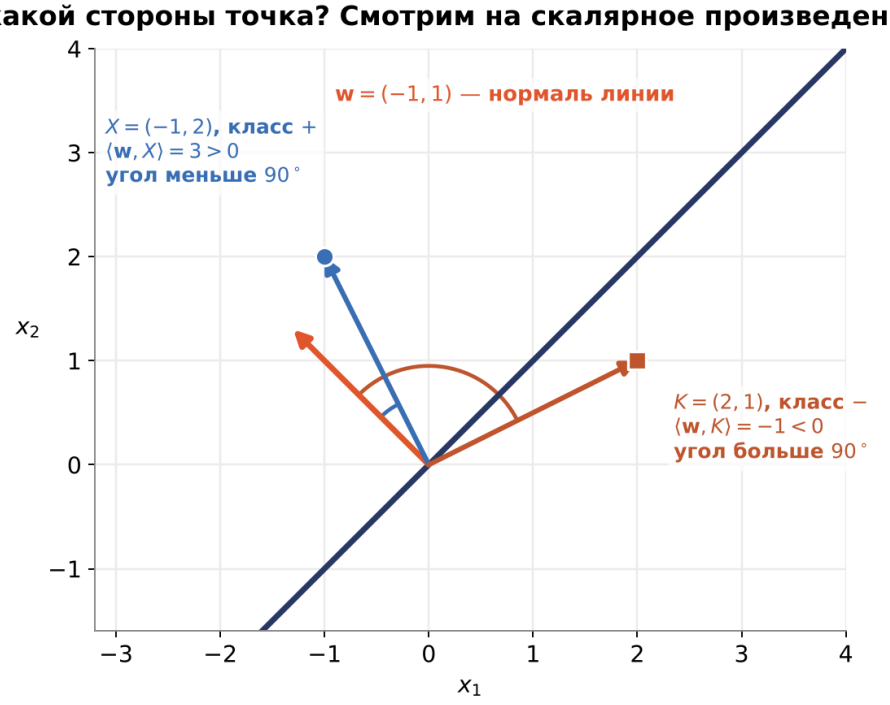
0.4. Как найти ширину и с какой стороны точка

Слева линия 1 с узкой полосой, справа линия 2 с широкой. Мы видим, что линия 2 имеет большую ширину, чем линия 1.



Как можно найти ширину прямой? Сначала нужно научиться определять, с какой стороны от линии находится точка. Для этого берём скалярное произведение этой точки и нормали этой прямой. Соответственно, параметр, который мы будем искать, — это параметр, который задаёт нормаль нашей разделяющей прямой, вектор $\mathbf{w}$.

Для простоты возьмём линию, проходящую через начало координат ($b = 0$), с нормалью $\mathbf{w} = (-1, 1)$.



- Точка $X = (-1, 2)$ из положительного класса: угол между ней и $\mathbf{w}$ меньше $90°$, скалярное произведение $\langle \mathbf{w}, X \rangle = 1 + 2 = 3 > 0$.

- Точка $K = (2,\ 1)$ из отрицательного класса: угол больше $90°$, скалярное произведение $\langle \mathbf{w}, K \rangle = -2 + 1 = -1 < 0$.

Если записать метки классов как $y = +1$ и $y = -1$, то в обоих случаях произведение положительное: $1 \cdot 3 = 3 > 0$ и $(-1) \cdot (-1) = 1 > 0$. Поэтому «все точки лежат по свою сторону линии» записывается одним условием:

$$y_i \, \langle \mathbf{w},\, x_i \rangle > 0 \quad \text{для всех точек } i$$

Если линия не проходит через начало координат, добавляется смещение b:

$$y_i \, (\mathbf{w} \cdot x_i + b) > 0$$

Дальше мы усилим это условие до ≥ 1 (шаг 4). А чтобы найти ширину, нам нужно уметь измерять расстояние от точки до линии. Этому посвящены шаги 1–3, а саму ширину мы выведем в шаге 4.6.

---

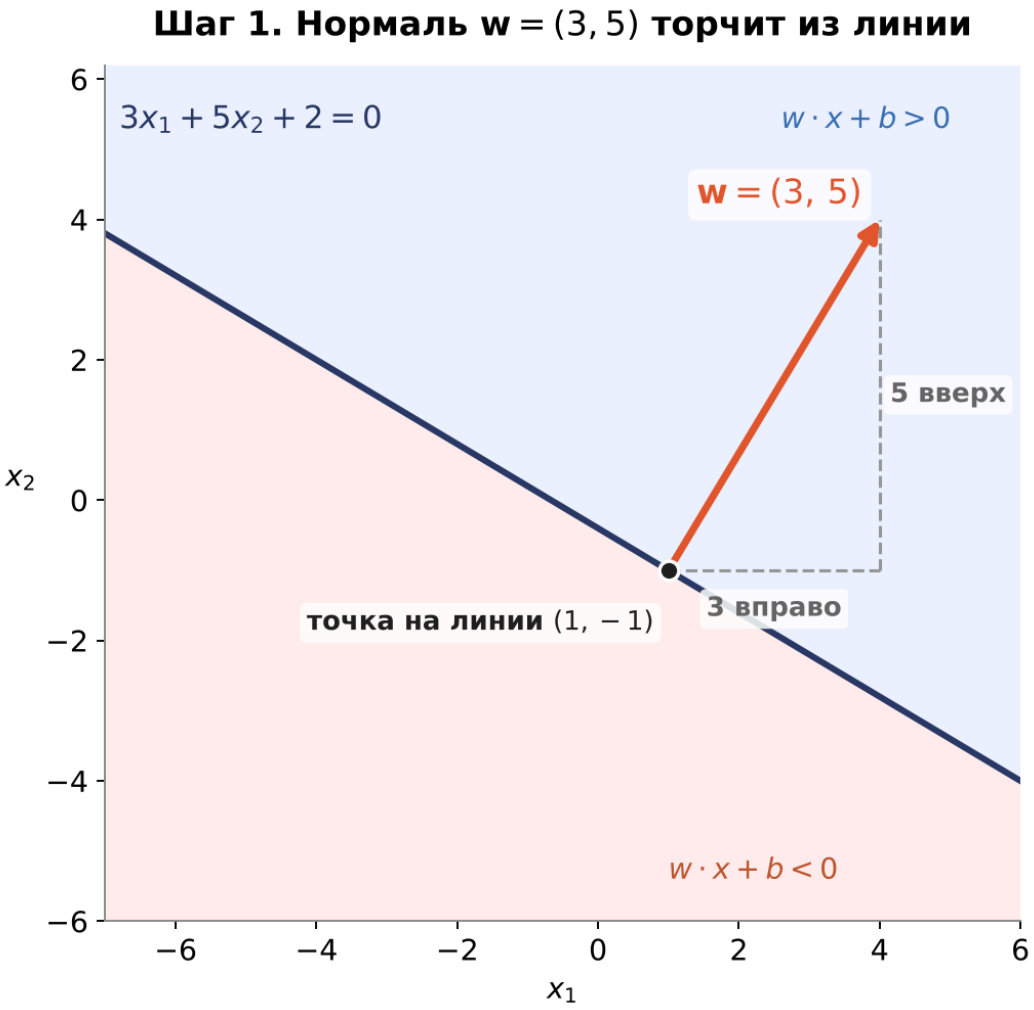
1. Нормаль к линии

Строим перпендикуляр к линии $3x_1 + 5x_2 + 2 = 0$. Такой перпендикуляр называется **нормалью**.

Как получить вектор нормали. Смотрим на исходную формулу $3x_1 + 5x_2 + 2 = 0$ и выдёргиваем оттуда коэффициенты при x_1 и x_2. Составляем из них вектор:

$$\mathbf{w} = (3,\ 5)$$

Это и есть вектор нормали. Отдельно считать ничего не нужно: он «читается» прямо из уравнения. Свободный член $+2$ в вектор не входит, он нужен только для положения линии.



Как читать график: вектор $\mathbf{w} = (3, 5)$ нарисован из точки $(1, -1)$, которая лежит на линии. Проверка: $3 \cdot 1 + 5 \cdot (-1) + 2 = 3 - 5 + 2 = 0$. От этой точки идём вправо по x_1 на 3 единицы и вверх по x_2 на 5 единиц.

Факты о нормали:

- Она не лежит на линии, она торчит из неё строго перпендикулярно.
- Она содержит всю необходимую информацию о наклоне линии $3x_1 + 5x_2 + 2 = 0$. Если поменять $\mathbf{w}$, наклон линии поменяется.

Пока это только утверждение. В следующем шаге проверим его.

---

2. Проверяем перпендикулярность: связь линии и вектора нормали

Вопрос. Как убедиться, что вектор $(3, 5)$ действительно описывает линию $3x_1 + 5x_2 + 2 = 0$, а не какую-то другую?

Идея. Если $\mathbf{w}$ перпендикулярен линии, то он должен быть перпендикулярен любому вектору, который лежит на этой линии. Проверим это на одном таком векторе.

2.1. Берём две точки на линии

Важно не запутаться: обе точки берём именно **из самой линии** $3x_1 + 5x_2 + 2 = 0$. Они нужны, чтобы построить вектор, который лежит на линии.

$$A = (1,\, -1) \qquad 3 \cdot 1 + 5 \cdot (-1) + 2 = 0 \;\checkmark$$

$$B = (-4,\, 2) \qquad 3 \cdot (-4) + 5 \cdot 2 + 2 = 0 \;\checkmark$$

2.2. Строим вектор из двух точек

Правило: **конец минус начало**. Вектор, идущий из точки A в точку B, равен координатам B минус координаты A, покоординатно:

$$\vec{AB} = B - A = \big(-4 - 1,\; 2 - (-1)\big) = (-5,\, 3)$$

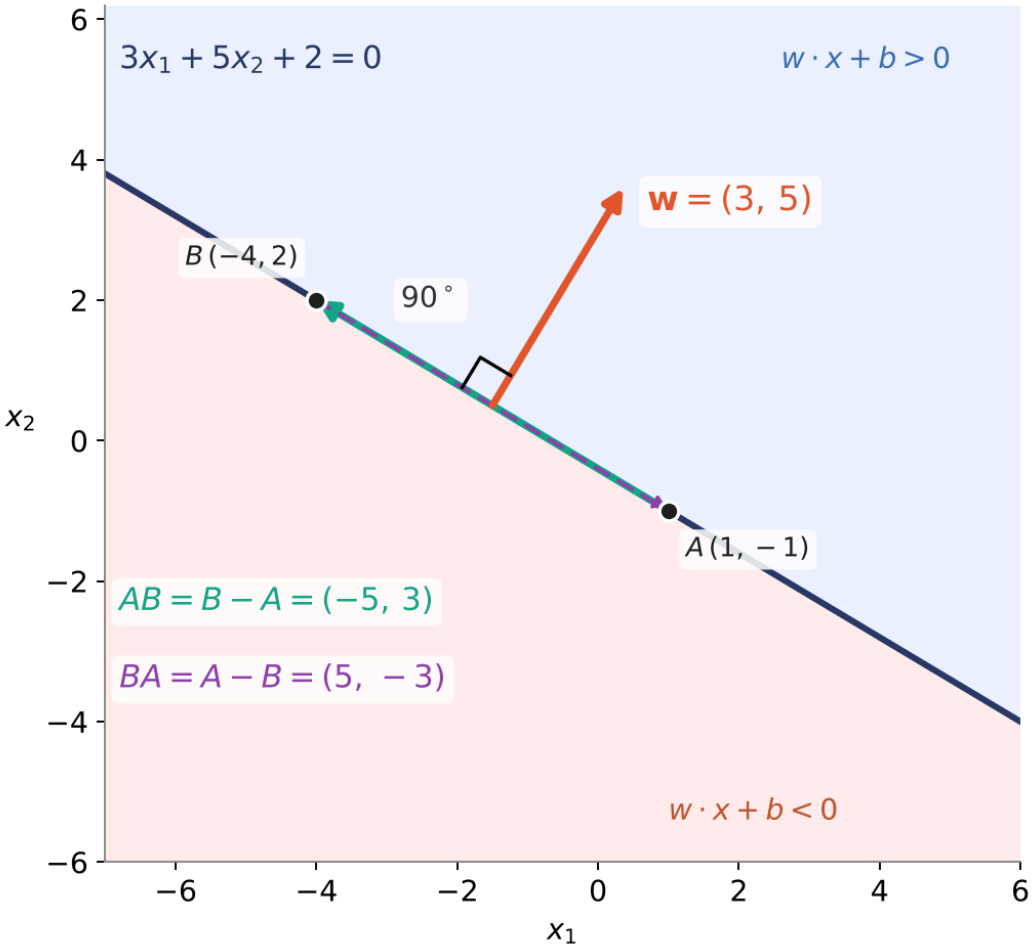
Это стрелка, которая лежит прямо на нашей линии.

Обратный вариант тоже верен. Вектор из B в A:

$$\vec{BA} = A - B = \big(1 - (-4),\; -1 - 2\big) = (5,\, -3)$$

$\vec{BA}$ — тот же вектор с обратным знаком ($\vec{BA} = -\vec{AB}$). Они оба лежат на одной линии, просто смотрят в разные стороны, поэтому подходит любой из них.

Шаг 2. AB **лежит на линии,** $\mathbf{w} \perp AB$



2.3. Скалярное произведение (кратко)

Скалярное произведение двух векторов показывает, насколько они сонаправлены:

$$\mathbf{a} \cdot \mathbf{b} = a_1 b_1 + a_2 b_2 = |\mathbf{a}|\,|\mathbf{b}| \cos\theta$$

- больше нуля — векторы смотрят примерно в одну сторону;
- меньше нуля — примерно в противоположные;
- ноль — угол между ними 90°, то есть они перпендикулярны.

2.4. Проверяем угол между $\mathbf{w}$ и $\vec{AB}$

$$\mathbf{w} \cdot \vec{AB} = 3 \cdot (-5) + 5 \cdot 3 = -15 + 15 = 0$$

Ноль означает, что угол между ними равен 90°, то есть они **перпендикулярны**.

Вывод. $\mathbf{w} = (3,\,5)$ действительно перпендикулярен линии $3x_1 + 5x_2 + 2 = 0$. Для обратного вектора $\vec{BA}$ результат тот же: $3 \cdot 5 + 5 \cdot (-3) = 0$.

---

3. Расстояние от точки до гиперплоскости

Теперь самое важное для SVM: как посчитать расстояние от точки до линии.

3.1. Какие точки берём

Не путаем две точки:

- $x_p = (1,\ -1)$ — точка **на линии** (мы её уже использовали, это A);
- $x_0 = (-3,\ -2)$ — точка **вне линии**, расстояние до которой хотим найти.

Проверим, что x_0 не лежит на линии: $3 \cdot (-3) + 5 \cdot (-2) + 2 = -9 - 10 + 2 = -17$. Не ноль, значит точка вне линии.

От точки на линии строим вектор до точки x_0. Правило то же: «конец минус начало».

$$\mathbf{v} = x_0 - x_p = \big(-3 - 1,\ -2 - (-1)\big) = (-4,\ -1)$$

Вектор $\mathbf{v}$ выходит из точки x_p.

3.2. Раскладываем $\mathbf{v}$ на две составляющие

Вектор $\mathbf{v}$ можно разложить на:

- составляющую **вдоль линии** (зелёная стрелка на графике);
- составляющую **вдоль нормали $\mathbf{w}$** (красная стрелка).

Длина красной составляющей — это и есть искомое расстояние d: она идёт от основания перпендикуляра на линии прямо до x_0.



3.3. Что такое $\mathbf{w}/\|\mathbf{w}\|$

Нормаль $\mathbf{w} = (3,\ 5)$ показывает направление, но у неё своя длина. Для измерения расстояния нужна стрелка длины ровно 1 в том же направлении. Получаем её делением на длину:

$$\|\mathbf{w}\| = \sqrt{3^2 + 5^2} = \sqrt{34} \approx 5.83$$

$$\frac{\mathbf{w}}{\|\mathbf{w}\|} = \frac{(3,\ 5)}{5.83} \approx (0.51,\ 0.86)$$

Это **единичный вектор нормали**. На графике он показан тёмной короткой стрелкой из x_p: то же направление, что у $\mathbf{w}$, но длина 1. Его удобно использовать как линейку.

3.4. Расстояние — это проекция $\mathbf{v}$ на $\mathbf{w}/\|\mathbf{w}\|$

Проекция вектора на единичный вектор — это просто скалярное произведение с ним:

$$\text{проекция} = \mathbf{v} \cdot \frac{\mathbf{w}}{\|\mathbf{w}\|} = \frac{\mathbf{v} \cdot \mathbf{w}}{\|\mathbf{w}\|}$$

Считаем по шагам:

$$\mathbf{v} \cdot \mathbf{w} = (-4) \cdot 3 + (-1) \cdot 5 = -12 - 5 = -17$$

$$\text{проекция} = \frac{-17}{\sqrt{34}} \approx \frac{-17}{5.83} \approx -2.92$$

Знак минус говорит о том, что x_0 лежит с **обратной** от $\mathbf{w}$ стороны: нормаль $\mathbf{w}$ смотрит вверх-вправо, а x_0 находится вниз-влево от линии. Само расстояние всегда положительное, поэтому берём модуль:

$$d = \frac{|-17|}{\sqrt{34}} \approx 2.92$$

Проверка по графику: красная стрелка идёт из $(-1.5,\, 0.5)$ в $(-3,\, -2)$, её длина $\sqrt{1.5^2 + 2.5^2} = \sqrt{8.5} \approx 2.92$. ✓

3.5. Избавляемся от выбора точки x_p

Согласитесь, неудобно каждый раз искать конкретную точку на линии и от неё считать проекцию. Давайте уберём этот шаг, чтобы считать расстояние сразу по самой точке x_0.

До сих пор мы просто делали обычную вещь: взяли один вектор, спроектировали на другой и получили расстояние. Теперь упростим формулу.

Расписываем $\mathbf{v} = x_0 - x_p$:

$$d = \frac{|\mathbf{w} \cdot \mathbf{v}|}{\|\mathbf{w}\|} = \frac{|\mathbf{w} \cdot (x_0 - x_p)|}{\|\mathbf{w}\|} = \frac{|\mathbf{w} \cdot x_0 - \mathbf{w} \cdot x_p|}{\|\mathbf{w}\|}$$

Точка x_p лежит **на линии**, значит удовлетворяет её уравнению:

$$\mathbf{w} \cdot x_p + b = 0 \quad \Longrightarrow \quad \mathbf{w} \cdot x_p = -b$$

Проверка на числах: $\mathbf{w} \cdot x_p = 3 \cdot 1 + 5 \cdot (-1) = -2$, и действительно $-b = -2$.

Подставляем $-b$ вместо $\mathbf{w} \cdot x_p$:

$$d = \frac{|\mathbf{w} \cdot x_0 - (-b)|}{\|\mathbf{w}\|}$$

Минус на минус даёт плюс. Итоговая формула:

$$\boxed{d = \frac{|\mathbf{w} \cdot x_0 + b|}{\|\mathbf{w}\|}}$$

Проверяем на нашем примере:

$$\mathbf{w} \cdot x_0 + b = 3 \cdot (-3) + 5 \cdot (-2) + 2 = -17 \qquad \Rightarrow \qquad d = \frac{|-17|}{\sqrt{34}} \approx 2.92$$

Получилось то же самое число, что и через x_p.

3.6. Что нам это дало

Мы избавились от необходимости знать точку на плоскости. Теперь для расстояния нужны только:

- параметры самой гиперплоскости $\mathbf{w}$ и b;
- координаты точки x_0 вне плоскости.

Заодно получили бонус: знак выражения $\mathbf{w} \cdot x_0 + b$ говорит, по какую сторону от плоскости лежит точка (на графиках это синяя и розовая области). Здесь он отрицательный (-17), то есть точка с обратной от $\mathbf{w}$ стороны. Именно на этом держится классификация в SVM.

---

4. Опорные векторы и «канонический» вид

Из шага 3 нам нужна только одна формула, запомните её:

$$d = \frac{|\mathbf{w} \cdot x_0 + b|}{\|\mathbf{w}\|}$$

Дальше она понадобится, чтобы посчитать ширину зазора.

4.1. Опорные векторы

Среди всех точек обучающей выборки есть те, что находятся **ближе всего** к разделяющей линии. Их называют **опорными векторами** (support vectors). Именно они определяют границу зазора: если сдвинуть любую другую точку, не заходя в зазор, линия не изменится, а если сдвинуть опорную, изменится.

На графиках ниже опорные векторы обведены кружком: по одному ближайшему на каждый класс. Синие круги — класс $+1$, красные квадраты — класс -1.

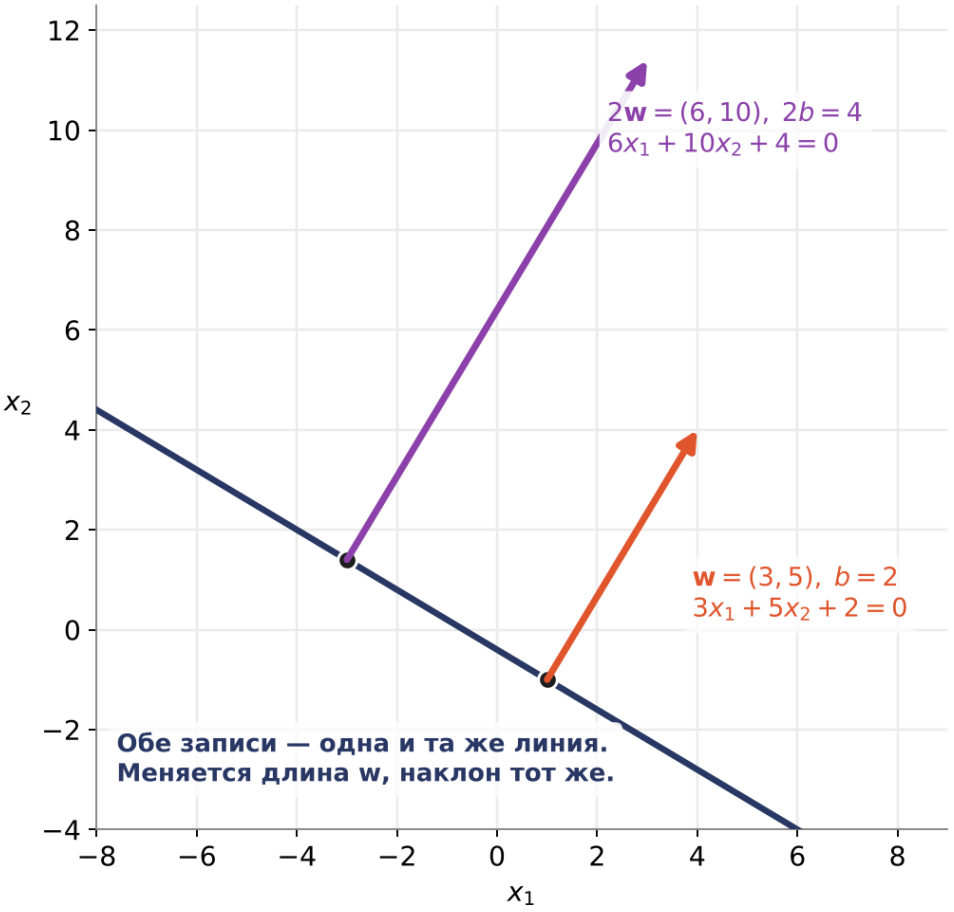
4.2. У одной линии бесконечно много записей

Уравнение $\mathbf{w} \cdot \mathbf{x} + b = 0$ можно масштабировать: умножить и $\mathbf{w}$, и b на любое число $k \neq 0$. Линия геометрически не изменится. Пример с $k = 2$:

$$3x_1 + 5x_2 + 2 = 0 \quad \xrightarrow{\cdot 2} \quad 6x_1 + 10x_2 + 4 = 0$$

Это одна и та же линия. Меняется только длина вектора нормали: $\mathbf{w} = (3,\, 5)$ превращается в $(6,\, 10)$, а направление остаётся прежним.

Шаг 4а. Одну линию можно записать разными числами



Значит, у одной линии бесконечное количество вариантов записи. А раз мы можем выбрать любой, **выбираем самый удобный**.

4.3. Какой масштаб удобнее всего

Хотим, чтобы по результату $\mathbf{w} \cdot x + b$ можно было сразу читать ответ:

- результат $\geq +1$ — точка положительного класса;
- результат ≤ -1 — точка отрицательного класса.

Для этого договоримся зафиксировать масштаб так, чтобы для **ближайших** точек (опорных векторов) выполнялось ровно:

$$\mathbf{w} \cdot x + b = +1 \quad \text{для ближайших точек класса } +1$$

$$\mathbf{w} \cdot x + b = -1 \quad \text{для ближайших точек класса } -1$$

Это две параллельные линии по обе стороны от разделяющей. Между ними лежит «нейтральная полоса», в которой обучающих точек нет вообще.

4.4. Как подогнать $\mathbf{w}$ и b: пример

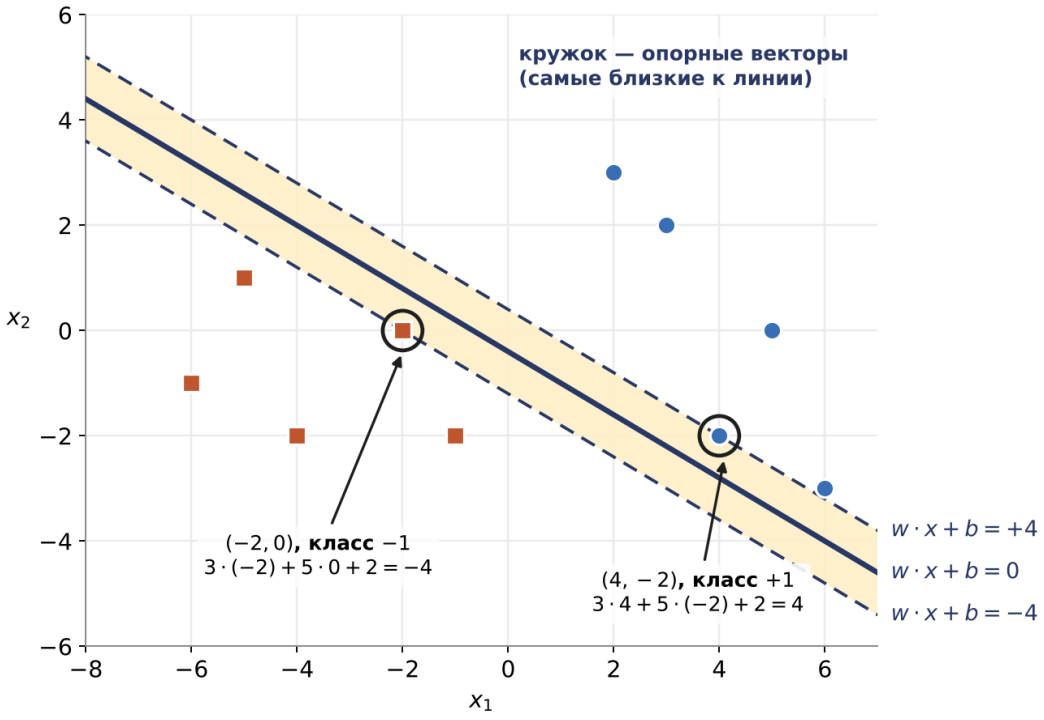
Возьмём наши данные. Ближайшие к линии $3x_1 + 5x_2 + 2 = 0$ точки:

$$\text{класс } +1: \ (4, -2) \ \Rightarrow \ 3 \cdot 4 + 5 \cdot (-2) + 2 = 4$$

$$\text{класс } -1: \ (-2, 0) \ \Rightarrow \ 3 \cdot (-2) + 5 \cdot 0 + 2 = -4$$

Получилось $+4$ и -4, а нужно $+1$ и -1.

Шаг 4б. Ближайшие к линии точки: значения +4 и −4



Вопрос: что сделать с $\mathbf{w}$ и b, чтобы вместо 4 и -4 получить 1 и -1?

Ответ: умножить их на $\frac{1}{4}$. Тогда все значения $\mathbf{w} \cdot x + b$ уменьшатся ровно в 4 раза.

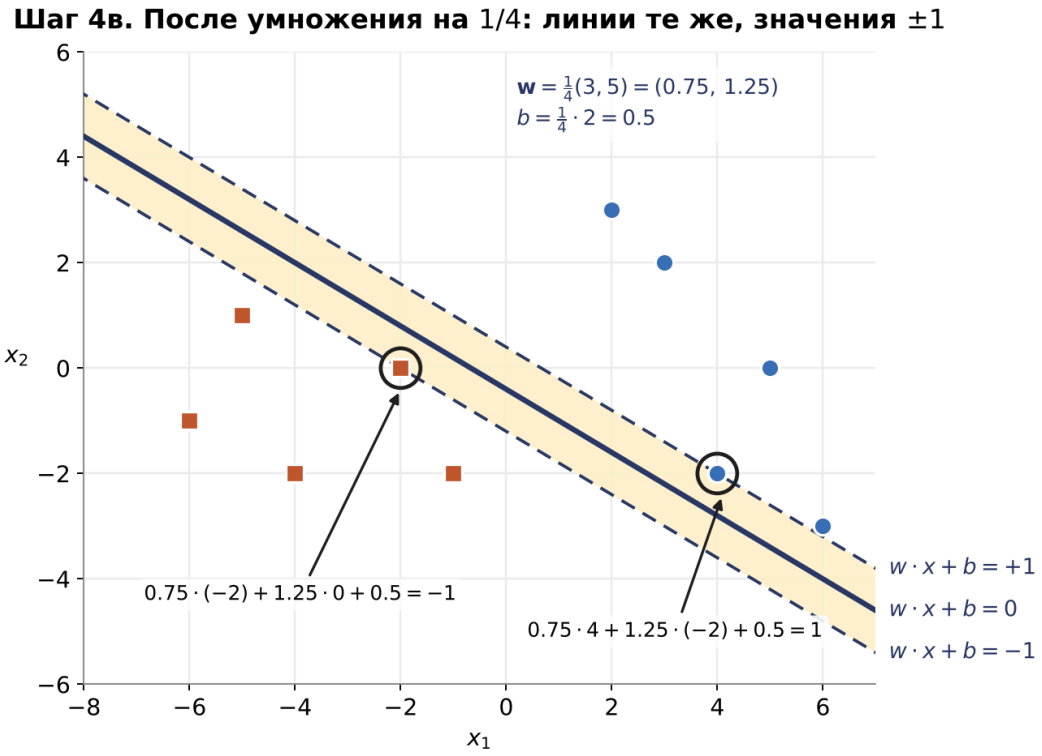
$$\mathbf{w} = \tfrac{1}{4} \cdot (3, \ 5) = (0.75, \ 1.25)$$

$$b = \tfrac{1}{4} \cdot 2 = 0.5$$

Проверяем:

$$0.75 \cdot 4 + 1.25 \cdot (-2) + 0.5 = 3 - 2.5 + 0.5 = 1 \ \checkmark$$

$$0.75 \cdot (-2) + 1.25 \cdot 0 + 0.5 = -1.5 + 0.5 = -1 \ \checkmark$$



Обратите внимание: линии на графике остались на тех же местах. Мы поменяли только числа в записи. В общем случае множитель равен единице, делённой на значение у ближайшей точки (в примере $k = 1/4$).

4.5. Одно условие вместо двух

Требования к классам можно записать одной формулой. Пусть $y_i = +1$ для класса $+1$ и $y_i = -1$ для класса -1.

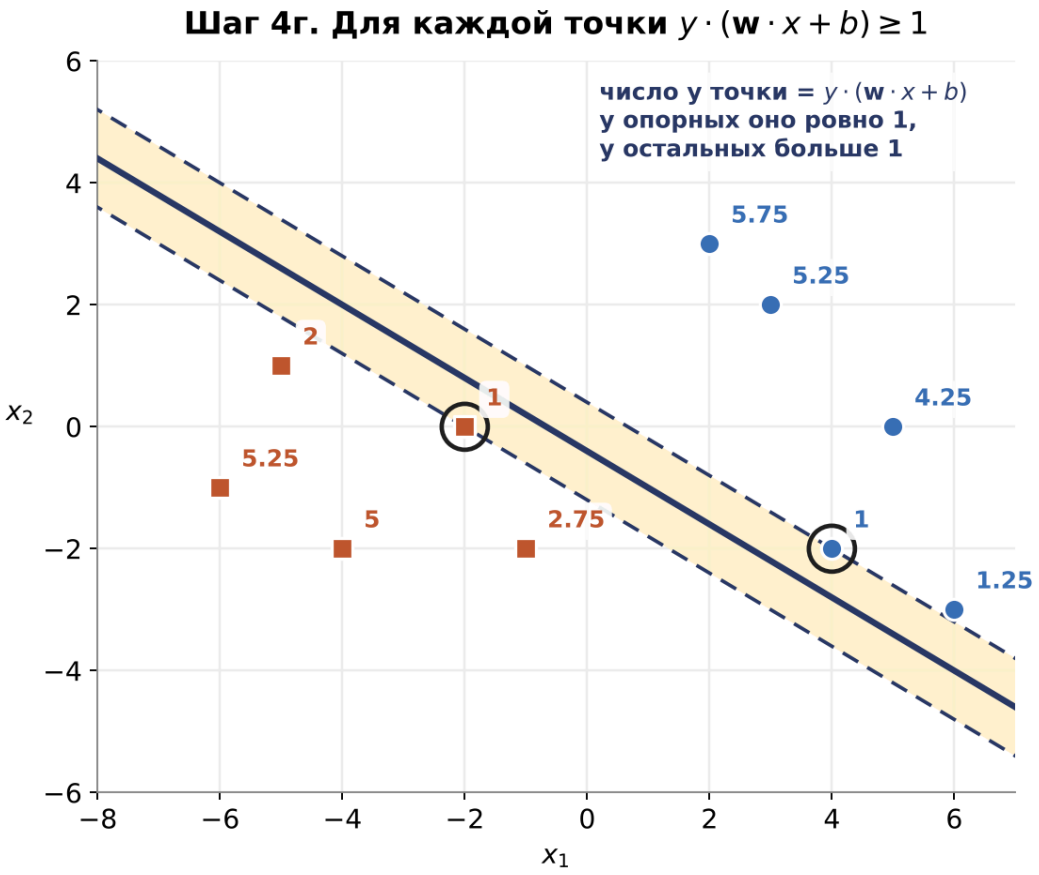
$$y_i \left(\mathbf{w} \cdot x_i + b \right) \geq 1$$

Почему это работает:

- при $y_i = +1$ получаем $\mathbf{w} \cdot x_i + b \geq 1$;
- при $y_i = -1$ умножение на -1 меняет знак неравенства: $-(\mathbf{w} \cdot x_i + b) \geq 1$, то есть $\mathbf{w} \cdot x_i + b \leq -1$.

То есть условие «результат ≥ 1 или ≤ -1» уже заложено в формулу с самого начала как ограничение.

На графике у каждой точки подписано значение $y \cdot (\mathbf{w} \cdot x + b)$: у опорных векторов ровно 1, у остальных больше.



4.6. Ширина зазора (margin)

Теперь выясним, чему равна ширина зазора. Именно её SVM старается сделать как можно больше.

Шаг 1. Две граничные гиперплоскости. Назовём их H_+ и H_-:

$$H_+ : \ \mathbf{w} \cdot x + b = +1 \qquad\qquad H_- : \ \mathbf{w} \cdot x + b = -1$$

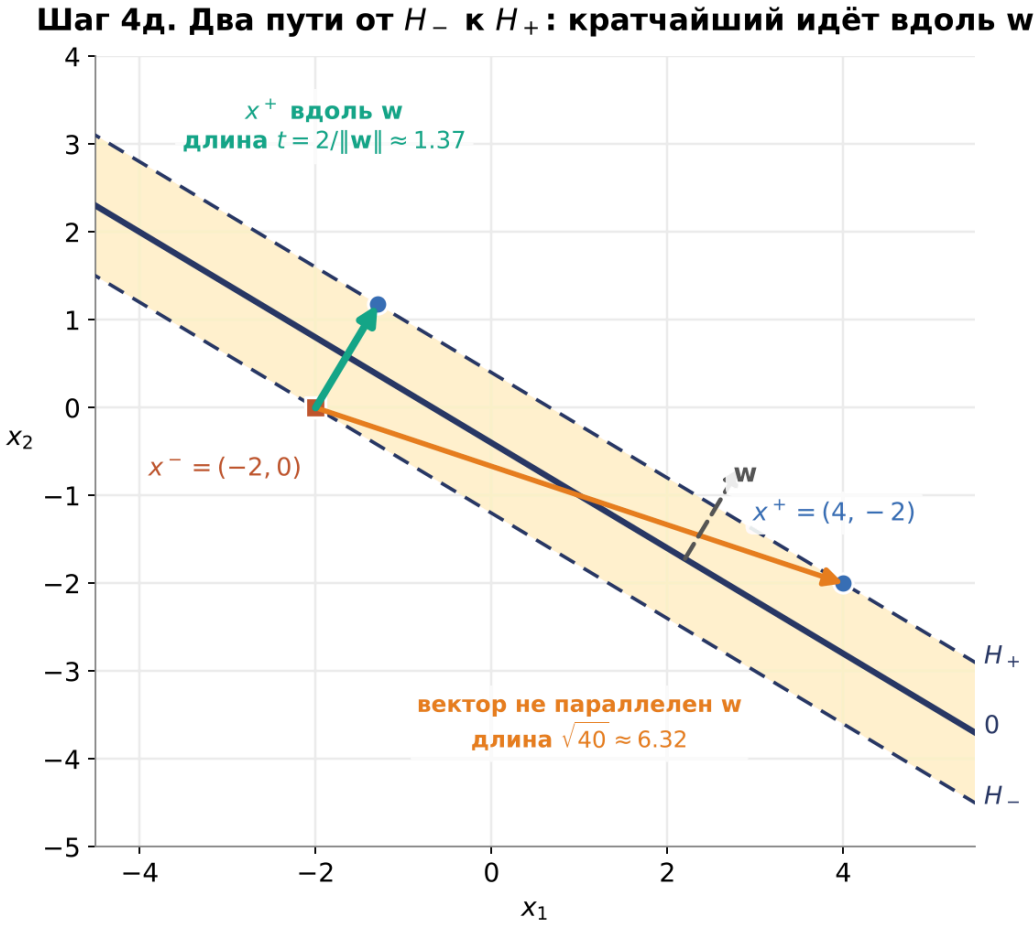
Возьмём любую точку x^+ на плоскости H_+ и любую точку x^- на плоскости H_-. Это просто точки на плоскостях, не обязательно из обучающей выборки. Для них выполняется:

$$\mathbf{w} \cdot x^+ + b = 1 \qquad\qquad \mathbf{w} \cdot x^- + b = -1$$

Шаг 2. Какое расстояние считаем. Расстояние между двумя параллельными плоскостями — это **кратчайший** путь от одной до другой. Из точки x^- до плоскости H_+ можно дойти по-разному (график ниже):

- наискосок, и тогда вектор $x^+ - x^-$ **не параллелен** $\mathbf{w}$: путь получается длиннее, как гипотенуза длиннее катета;
- строго поперёк, вдоль нормали, и тогда вектор $x^+ - x^-$ **параллелен** $\mathbf{w}$: это самый короткий путь.

Нам нужен второй вариант. На графике из точки $x^- = (-2,\ 0)$ наискосок до $(4,\ -2)$ получается $\sqrt{40} \approx 6.32$, а вдоль нормали всего около 1.37.



Шаг 3. Вычитаем уравнения. Из первого равенства вычитаем второе:

$$(\mathbf{w} \cdot x^+ + b) - (\mathbf{w} \cdot x^- + b) = 1 - (-1) = 2$$

Слагаемое b сокращается, а $\mathbf{w} \cdot x^+ - \mathbf{w} \cdot x^-$ собирается в одно скалярное произведение:

$$\mathbf{w} \cdot (x^+ - x^-) = 2$$

Шаг 4. Записываем вектор $x^+ - x^-$ через его длину. Поскольку $x^+ - x^-$ параллелен $\mathbf{w}$ (вектору нормали), его можно представить так:

$$x^+ - x^- = t \cdot \frac{\mathbf{w}}{\|\mathbf{w}\|}$$

Здесь:

- $\dfrac{\mathbf{w}}{\|\mathbf{w}\|}$ — единичный вектор в направлении нормали, его длина равна 1 (мы уже строили его в шаге 3.3);

- t — число (скаляр), длина вектора $x^+ - x^-$. Это и есть расстояние между плоскостями, которое мы ищем.

Шаг 5. Подставляем. Берём $\mathbf{w} \cdot (x^+ - x^-) = 2$ и вместо $x^+ - x^-$ ставим $t \cdot \dfrac{\mathbf{w}}{\|\mathbf{w}\|}$:

$$\mathbf{w} \cdot \left(t \cdot \frac{\mathbf{w}}{\|\mathbf{w}\|} \right) = 2$$

Число t можно вынести за скобки:

$$t \cdot \left(\frac{\mathbf{w} \cdot \mathbf{w}}{\|\mathbf{w}\|} \right) = 2$$

Дальше нужно упростить $\mathbf{w} \cdot \mathbf{w}$:

$$\frac{\mathbf{w} \cdot \mathbf{w}}{\|\mathbf{w}\|} = \frac{\|\mathbf{w}\|^2}{\|\mathbf{w}\|} = \|\mathbf{w}\|$$

Почему $\mathbf{w} \cdot \mathbf{w} = \|\mathbf{w}\|^2$? Это следует из двух определений. Длина вектора считается по теореме Пифагора:

$$\|\mathbf{w}\| = \sqrt{w_1^2 + w_2^2 + \cdots + w_n^2} \qquad \Longrightarrow \qquad \|\mathbf{w}\|^2 = w_1^2 + w_2^2 + \cdots + w_n^2$$

А скалярное произведение вектора на самого себя перемножает одинаковые координаты:

$$\mathbf{w} \cdot \mathbf{w} = w_1 \cdot w_1 + w_2 \cdot w_2 + \cdots + w_n \cdot w_n = w_1^2 + w_2^2 + \cdots + w_n^2$$

Справа получилось то же выражение. На числах для $\mathbf{w} = (3,\, 5)$: $\mathbf{w} \cdot \mathbf{w} = 9 + 25 = 34$ и $\|\mathbf{w}\|^2 = (\sqrt{34})^2 = 34$.

Шаг 6. Ответ. После упрощения остаётся:

$$t \cdot \|\mathbf{w}\| = 2 \qquad \Longrightarrow \qquad \boxed{t = \frac{2}{\|\mathbf{w}\|}}$$

Это и есть ширина зазора (margin).

Пример на числах

Проверим ту же логику на точках $x^+ = (4,\, 4)$ и $x^- = (-2,\, -6)$ в исходном масштабе, где $\mathbf{w} = (3,\, 5)$ и $b = 2$.

$\mathbf{w} \cdot x^+ + b = 3 \cdot 4 + 5 \cdot 4 + 2 = 34$ $\qquad$ $\mathbf{w} \cdot x^- + b = 3 \cdot (-2) + 5 \cdot (-6) + 2 = -34$

Здесь значения равны $+34$ и -34, а не ± 1, потому что масштаб ещё не нормирован. Рассуждение то же, но справа в шаге 3 стоит разность значений:

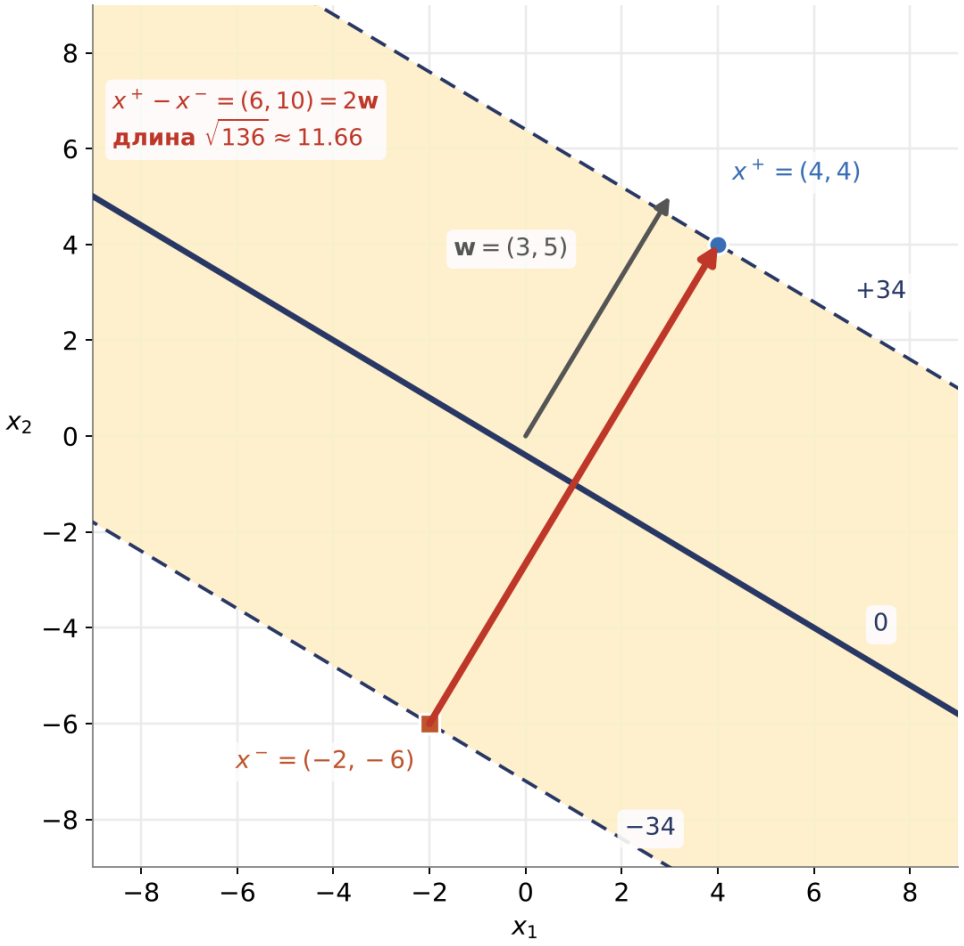
$$\mathbf{w} \cdot (x^+ - x^-) = 34 - (-34) = 68 \qquad \Longrightarrow \qquad t = \frac{68}{\|\mathbf{w}\|} = \frac{68}{\sqrt{34}} \approx 11.66$$

Измерим то же расстояние напрямую, как длину вектора между точками:

$$x^+ - x^- = (6,\, 10) \qquad \Longrightarrow \qquad \sqrt{(4-(-2))^2 + (4-(-6))^2} = \sqrt{136} \approx 11.66$$

Числа совпали, потому что вектор $(6,\, 10)$ равен $2\mathbf{w}$, то есть параллелен нормали.

Шаг 4е. Пример в исходном масштабе: значения +34 и −34



В «каноническом» масштабе значения равны ровно $+1$ и -1, поэтому вместо 68 справа всегда стоит 2. Отсюда и получается $t = 2/\|\mathbf{w}\|$. Для нашего $\mathbf{w} = (0.75,\, 1.25)$:

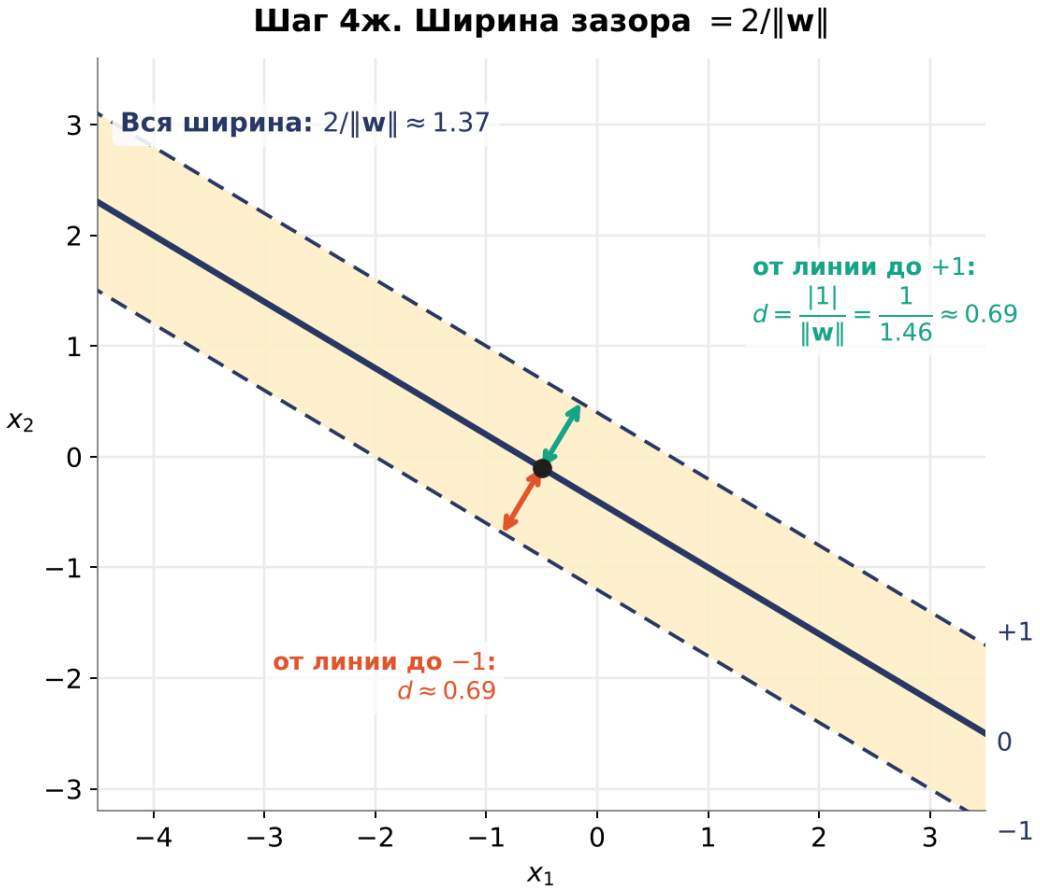
$$\|\mathbf{w}\| = \sqrt{0.75^2 + 1.25^2} = \sqrt{2.125} \approx 1.46 \qquad \Longrightarrow \qquad t = \frac{2}{1.46} \approx 1.37$$

Проверка вторым способом

Тот же результат даёт формула расстояния из шага 3. Точка на плоскости H_+ ($\mathbf{w} \cdot x + b = 1$) отстоит от разделяющей линии на

$$d = \frac{|1|}{\|\mathbf{w}\|} = \frac{1}{1.46} \approx 0.69$$

Столько же до плоскости H_-, значит вся ширина равна $2 \cdot 0.69 \approx 1.37$. Совпало.



Чем меньше $\|\mathbf{w}\|$, тем шире зазор. Это главная идея SVM.

4.7. Итоговая постановка задачи

Мы ищем $\mathbf{w}$ и b такие, что:

1. линия разделяет классы правильно;
2. для всех точек выполняется $y_i\,(\mathbf{w} \cdot x_i + b) \geq 1$ — это ограничение;
3. $\|\mathbf{w}\|$ как можно меньше — тогда ширина зазора $2/\|\mathbf{w}\|$ максимальна.

Итоговая цель:

$$\min_{\mathbf{w},\,b} \ \tfrac{1}{2}\,\|\mathbf{w}\|^2 \qquad \text{при условии} \qquad y_i\,(\mathbf{w} \cdot x_i + b) \geq 1 \ \text{ для всех точек } i$$

Здесь y_i — метка класса (истинная), то есть $+1$ или -1.

Почему именно $\frac{1}{2}\|\mathbf{w}\|^2$, а не просто $\|\mathbf{w}\|$.

- Ширина зазора равна $2/\|\mathbf{w}\|$, поэтому, чтобы её максимизировать, нужно минимизировать $\|\mathbf{w}\|$.
- Берём квадрат $\|\mathbf{w}\|^2$, потому что не хотим возиться с корнем. Нам не важно само значение $\|\mathbf{w}\|$, важно только сравнение и выбор лучшего. У $\|\mathbf{w}\|$ и $\|\mathbf{w}\|^2$ минимум достигается при одном и том же $\mathbf{w}$, так как оба растут вместе.
- Множитель $\frac{1}{2}$ добавляем, чтобы потом при взятии производной он сократился с двойкой: $\frac{d}{d\mathbf{w}}\left(\frac{1}{2}\|\mathbf{w}\|^2\right) = \mathbf{w}$.