SVM. Часть 3. Решение задачи: dual (двойственная постановка)

0. Итоговая цель и зачем нужен Лагранж

Из части 1 мы пришли к такой задаче:

$$\min_{\mathbf{w},\,b} \ \tfrac{1}{2}\,\|\mathbf{w}\|^2 \qquad \text{при условии} \qquad y_i\,(\mathbf{w}\cdot x_i + b) \geq 1 \ \text{ для всех точек } i$$

Здесь y_i — истинная метка класса ($+1$ или -1).

Это задача **условной оптимизации**: функцию нужно минимизировать, но при ограничениях-неравенствах. Просто взять производную и приравнять к нулю нельзя: ограничения мешают, минимум может лежать на границе допустимой области.

Метод Лагранжа — это способ встроить ограничения прямо в функцию. К ней добавляются слагаемые с ограничениями, умноженные на специальные числа (множители):

$$L(\mathbf{w},\,b,\,a) = \tfrac{1}{2}\|\mathbf{w}\|^2 - \sum_i a_i\big(y_i(\mathbf{w}\cdot x_i + b) - 1\big)$$

0.1. Что такое Лагранжиан

Лагранжиан — это новая функция, в которую в одно выражение собраны и то, что мы минимизируем, и ограничения. Для задачи «минимизировать $f(x)$ при ограничении $g(x) \geq 0$» он строится так:

$$L(x,\,a) = f(x) - a\,g(x), \qquad a \geq 0$$

- $f(x)$ — исходная функция, которую минимизируем (у нас это $\tfrac{1}{2}\|\mathbf{w}\|^2$);
- $g(x) \geq 0$ — ограничение, записанное в таком виде (у нас $y_i(\mathbf{w}\cdot x_i + b) - 1 \geq 0$);
- a — **множитель Лагранжа**, по одному на каждое ограничение. Его можно понимать как «цену» нарушения ограничения.

Главная идея: для допустимых x добавка $a\,g(x)$ неотрицательна и ничего не портит, а для недопустимых мы можем сделать её сколь угодно большой, выбрав большое a. Подробно это увидим на примере в разделе 1.

0.2. План решения

Решать будем в такой последовательности. Каждый пункт потом разберём на числах.

1. Записать ограничения в виде $g(x) \geq 0$.

2. Построить лагранжиан: $L(x,\, a) = f(x) - a\, g(x),\ \ a \geq 0$.
3. Записать исходную (**примальную**) задачу через лагранжиан: $\ p^* = \min_x \max_{a \geq 0} L(x,\, a)$.
4. Поменять $\min$ и $\max$ местами (**двойственная** задача): $\ d^* = \max_{a \geq 0} \min_x L(x,\, a)$. Для выпуклых задач ответ не меняется: $p^* = d^*$.
5. Решить внутреннюю задачу: взять производную $\dfrac{\partial L}{\partial x} = 0$ и выразить x через a.
6. Подставить найденное x обратно в L. Получится **двойственная функция** $D(a)$, которая зависит только от a.
7. Максимизировать $D(a)$ по $a \geq 0$ и найти a^*.
8. Восстановить ответ x^* из a^*.

Сначала пройдём все восемь шагов на простом примере, а потом повторим то же для SVM.

---

1. Простой пример: $\min x^2$ при $x \geq 1$

Ответ здесь очевиден: $x = 1$, минимум равен 1. Но решим задачу через Лагранжиан, чтобы увидеть весь метод.

1.1. Строим Лагранжиан

Запишем ограничение в форме $g(x) \geq 0$. У нас $g(x) = x - 1 \geq 0$.

$$L(x,\, a) = x^2 - a\,(x - 1), \qquad a \geq 0$$

- x^2 — то, что минимизируем;
- $a\,(x-1)$ — ограничение $g(x)$, умноженное на множитель a.

1.2. Почему именно минус

- Если x допустимо (то есть $x \geq 1$, значит $g(x) = x - 1 \geq 0$), то слагаемое $a(x-1)$ — неотрицательное число (раз $a \geq 0$ и $g(x) \geq 0$).
- Значит, вычитание этого слагаемого **уменьшает** L относительно исходной функции: $L(x, a) \leq x^2$.

Проверим на числах при $a = 1$:

x	**допустимо?**	$L(x, 1) = x^2 - (x-1)$	**сравнение с** x^2
3	да	$9 - 2 = 7$	$7 \leq 9$
2	да	$4 - 1 = 3$	$3 \leq 4$
1	да (граница)	$1 - 0 = 1$	$1 \leq 1$
-1	**нет**	$1 - (-2) = 3$	$3 > 1$

Для допустимых точек $L \le x^2$. Для недопустимой точки наоборот L становится **больше**, и дальше мы увидим, что это важно.

1.3. Что будет, если взять максимум по a

Для фиксированного x возьмём максимум L по $a \ge 0$:

$$\max_{a \ge 0} \left[x^2 - a(x-1) \right]$$

- Если $x - 1 > 0$ (строго, с запасом): при росте a слагаемое $-a(x-1)$ только уменьшается. Выгоднее всего взять $a = 0$, и максимум равен просто x^2.
- Если $x - 1 = 0$ (граница): слагаемое всегда 0 независимо от a, максимум опять x^2.
- Если x недопустимо ($x < 1$, значит $x - 1 < 0$): тогда $-a(x-1) = a\,(1-x) > 0$, и это растёт без ограничений при $a \to \infty$. Максимум равен $+\infty$.

Получаем красивый факт:

$$\max_{a \ge 0} L(x,\, a) = \begin{cases} x^2, & x \ge 1 \text{ (допустимо)} \\ +\infty, & x < 1 \text{ (недопустимо)} \end{cases}$$

То есть операция $\max L$ сама **запрещает недопустимые точки**: для них она выдаёт бесконечность.

Как именно получается $+\infty$. Здесь мы **максимизируем по** a: подбираем $a \ge 0$ так, чтобы L было как можно больше. Посмотрим на две точки.

Недопустимая точка $x = 0$: $L(0,\, a) = 0 - a\,(0-1) = a$.

a	$L(0,\, a)$
1	1
10	10
1000	1000
$1\,000\,000$	$1\,000\,000$

Чем больше a, тем больше L, и остановиться некуда. Наибольшего значения не существует, поэтому говорим, что максимум равен $+\infty$. Причина: у недопустимой точки $x - 1$ отрицательное, а перед скобкой стоит минус. Минус на минус даёт плюс, и слагаемое $-a(x-1)$ растёт вместе с a.

Допустимая точка $x = 3$: $L(3,\, a) = 9 - a \cdot 2 = 9 - 2a$. Здесь с ростом a значение **падает**, поэтому максимум достигается при $a = 0$ и равен 9, то есть просто x^2.

1.4. Что это значит

1. На первом этапе (по a) мы перебираем значения, и иногда получаем даже $+\infty$, потому что ищем максимум.
2. На втором этапе (по x) мы ищем **минимум**, поэтому точки с $+\infty$ автоматически отбрасываются.

$$\min_x \Big[\max_{a\geq 0} L(x,\, a)\Big] = \min_{x\geq 1} x^2$$

Это в точности исходная задача. Её называют **примальной**:

$$p^* = \min_x \max_{a\geq 0} L(x,\, a)$$

Как читать эту запись. Читаем изнутри наружу, как скобки:

1. **Внутри — $\max$ по a.** Для каждого фиксированного x ищем самое большое L, подбирая a. Делаем это не ради самого a, а чтобы отсеять недопустимые x: у них получается $+\infty$, а у допустимых просто x^2. Можно считать, что a работает как «проверяющий», которому разрешено ставить сколь угодно большой штраф за нарушение.
2. **Снаружи — $\min$ по x.** Среди получившихся значений ищем наименьшее. Бесконечности проигрывают, остаётся x^2 при $x \geq 1$.

Итак, настоящая минимизируемая переменная здесь x, а a только помогает «выбросить» запрещённые точки.

1.5. Переставляем min и max: переход к двойственной

Двойственная задача — это то же самое, но $\min$ и $\max$ меняются местами:

$$d^* = \max_{a\geq 0}\ \min_x\ L(x,\, a)$$

Как читать эту запись. Роли поменялись:

1. **Внутри — $\min$ по x.** Для каждого фиксированного a находим x, при котором L минимально. Это обычная минимизация без ограничений, поэтому подходит просто производная.
2. **Снаружи — $\max$ по a.** Теперь главная переменная — a: мы ищем то a, при котором получившееся значение самое большое.

То есть в двойственной задаче мы **максимизируем по** a, а x потом восстанавливаем из найденного a (в примере $x = a/2$).

Зачем так делать? Есть общий факт, он верен всегда:

$$\max_a \min_x L(x,\, a)\ \leq\ \min_x \max_a L(x,\, a) \qquad \text{то есть} \qquad d^* \leq p^*$$

Порядок важен: в первом случае мы сначала ищем минимум, потом максимум, во втором наоборот, поэтому результаты могут отличаться. Такое неравенство

называется **слабой двойственностью**.

Когда неравенство становится равенством? Для выпуклых задач (у нас x^2 выпукла, ограничение линейное) при **условии Слейтера** (грубо говоря, есть хотя бы одна строго допустимая точка) работает **сильная двойственность**:

$$d^* = p^*$$

1.6. Решаем двойственную задачу

Шаг 1. Внутренний минимум по x (при фиксированном a).

$$L(x,\,a) = x^2 - ax + a \qquad \Rightarrow \qquad \frac{\partial L}{\partial x} = 2x - a = 0 \quad \Rightarrow \quad x^* = \frac{a}{2}$$

Шаг 2. Подставляем $x = a/2$ **обратно.** Получается двойственная функция $D(a)$:

$$D(a) = \left(\frac{a}{2}\right)^2 - a \cdot \frac{a}{2} + a = -\frac{a^2}{4} + a$$

Шаг 3. Внешний максимум по $a \geq 0$**.**

$$\frac{dD}{da} = -\frac{a}{2} + 1 = 0 \quad \Rightarrow \quad a^* = 2 \qquad \Rightarrow \qquad D(2) = -\frac{4}{4} + 2 = 1$$

Получили $d^* = 1$, и это **точно совпало** с $p^* = 1$, которое мы нашли сразу (там и так было очевидно).

Момент красивый: $x^* = a^*/2 = 1$. То есть, зная оптимальное a, мы можем восстановить оптимальное x. Точно так же в SVM: зная оптимальные a_i, мы восстановим $\mathbf{w}$.

1.7. Та же схема в общем виде

Для ограничения-равенства $h(x) = 0$ Лагранжиан такой: $L(x, \lambda) = f(x) + \lambda\, h(x)$, где f — то, что минимизируем, λ — множитель. Дальше всегда два шага:

1. минимизируем L по x (внутренняя задача) и получаем функцию $D(\lambda)$ — это и есть **двойственная функция**;
2. максимизируем $D(\lambda)$ по λ (внешняя задача), получаем λ^*, а из него — x^*.

Пример: $x^2 \to \min$ при $x - 1 = 0$.

$$L = x^2 + \lambda(x - 1), \qquad \frac{\partial L}{\partial x} = 2x + \lambda = 0 \;\Rightarrow\; x = -\frac{\lambda}{2}$$

$$D(\lambda) = \left(-\frac{\lambda}{2}\right)^2 + \lambda\left(-\frac{\lambda}{2} - 1\right) = -\frac{\lambda^2}{4} - \lambda$$

$$D'(\lambda) = -\frac{\lambda}{2} - 1 = 0 \;\Rightarrow\; \lambda^* = -2, \qquad x^* = -\frac{\lambda^*}{2} = 1, \qquad D(-2) = -1 + 2 = 1$$

Значение двойственной функции снова совпало с примальным. Это сильная двойственность (для выпуклых задач так и должно быть).

> Разница между двумя примерами: у равенства $h(x) = 0$ множитель λ может быть любого знака (получилось $\lambda^* = -2$), а у неравенства $g(x) \geq 0$ множитель обязан быть $a \geq 0$.

---

2. То же самое для SVM

2.1. Ограничений теперь много

$$\min_{\mathbf{w},\, b} \ \tfrac{1}{2}\|\mathbf{w}\|^2 \qquad \text{при} \qquad y_i(\mathbf{w} \cdot x_i + b) - 1 \geq 0 \ \text{ для всех } i$$

Ограничений много: по одному на каждую точку. Поэтому множитель не один, а целый вектор $a_1, \ldots, a_n \geq 0$ — **по множителю на каждую точку**.

2.2. Лагранжиан

$$L(\mathbf{w},\, b,\, a) = \tfrac{1}{2}\|\mathbf{w}\|^2 - \sum_{i=1}^{n} a_i \big[\, y_i(\mathbf{w} \cdot x_i + b) - 1 \,\big]$$

Минус стоит по той же причине, что и в простом примере (шаг 1.2): для допустимых точек он уменьшает L, для недопустимых даёт бесконечность при взятии максимума.

2.3. Примальная и двойственная задачи

$$p^* = \min_{\mathbf{w},\, b} \ \max_{a \geq 0} \ L(\mathbf{w},\, b,\, a) \qquad\qquad d^* = \max_{a \geq 0} \ \min_{\mathbf{w},\, b} \ L(\mathbf{w},\, b,\, a)$$

Наша задача выпуклая: квадратичная целевая функция и линейные ограничения. Условие Слейтера выполняется (если классы разделимы линией, а именно это мы предполагаем в этой части). Поэтому $p^* = d^*$, и можно решать двойственную.

2.4. Внутренняя задача: минимум по $\mathbf{w}$ и b

Берём частные производные.

По $\mathbf{w}$:

$$\frac{\partial L}{\partial \mathbf{w}} = \mathbf{w} - \sum_i a_i y_i x_i = 0 \quad \Rightarrow \quad \boxed{\mathbf{w} = \sum_i a_i y_i x_i}$$

Мы получили $\mathbf{w}$ через a.

По b:

$$\frac{\partial L}{\partial b} = -\sum_i a_i y_i = 0 \quad \Rightarrow \quad \boxed{\sum_i a_i y_i = 0}$$

Это условие не даёт формулу для b в явном виде. Оно становится **ограничением** для двойственной задачи.

2.5. Подставляем найденное $\mathbf{w}$ обратно в L

$$L = \tfrac{1}{2}\Big(\sum_i a_i y_i x_i\Big) \cdot \Big(\sum_j a_j y_j x_j\Big) - \sum_i a_i y_i \Big(\sum_j a_j y_j x_j\Big) \cdot x_i - b\sum_i a_i y_i + \sum_i a_i$$

Дальше упрощаем:

- слагаемое $-b\sum_i a_i y_i$ равно нулю по условию из шага 2.4;
- первое и второе слагаемые одинаковой формы: от $\frac{1}{2}$ вычитается 1, остаётся $-\frac{1}{2}$.

Итог (**двойственная задача SVM**):

$$\max_a \sum_{i=1}^{n} a_i \; - \; \frac{1}{2}\sum_{i=1}^{n}\sum_{j=1}^{n} a_i a_j \, y_i y_j \, (x_i \cdot x_j)$$

$$\text{при условиях} \qquad a_i \geq 0 \;\; \text{для всех } i, \qquad \sum_{i=1}^{n} a_i y_i = 0$$

Обратите внимание: признаки x_i входят только в виде **скалярных произведений** $x_i \cdot x_j$. Именно это позволит позже заменить их на ядро.

2.6. Почему работают только опорные точки

В простом примере с двумя ограничениями $x - 1 \geq 0$ и $x - 3 \geq 0$ первое условие лишнее: если выполнено второе, то первое выполняется с запасом. Здесь срабатывают условия **KKT**: у каждого ограничения свой множитель, и для ограничений, которые выполняются с запасом, множитель обнуляется.

Для SVM это записывается так:

$$a_i \left[\, y_i(\mathbf{w} \cdot x_i + b) - 1 \,\right] = 0 \quad \text{для каждой точки } i$$

Два случая:

- точка лежит **строго вне** зазора ($y_i(\mathbf{w} \cdot x_i + b) > 1$): скобка не ноль, значит $a_i = 0$. Точка **не учитывается**;
- $a_i > 0$: тогда скобка равна нулю, то есть $y_i(\mathbf{w} \cdot x_i + b) = 1$. Точка лежит ровно на границе зазора. Это **опорная точка**.

Поэтому в формуле $\mathbf{w} = \sum_i a_i y_i x_i$ реально остаются только **опорные точки**, все остальные слагаемые равны нулю.

---

3. Как решать задачу про a (метод SMO)

Мы получили задачу:

$$\max_a \sum_i a_i - \frac{1}{2}\sum_i \sum_j a_i a_j \, y_i y_j \, (x_i \cdot x_j) \qquad \text{при} \qquad a_i \geq 0, \quad \sum_i a_i y_i = 0$$

3.1. Почему нельзя просто «подниматься по градиенту»

Что такое обычный подъём. Так мы обучали primal: считаем производную и сдвигаем параметры в сторону улучшения. Сейчас мы **максимизируем** функцию $f(a)$, поэтому для каждого a_i берём производную $\dfrac{\partial f}{\partial a_i}$ и двигаем a_i вверх:

$$a_i \leftarrow a_i + \alpha \frac{\partial f}{\partial a_i}$$

Каждое a_i двигается **независимо** от остальных.

Что ломается. У нас есть условие

$$\sum_i a_i y_i = 0$$

Оно связывает все a_i между собой. Возьмём простой пример: три точки с метками $y = (+1,\ +1,\ -1)$. Условие для них:

$$a_1 + a_2 - a_3 = 0$$

Пусть сейчас $a = (1,\ 1,\ 2)$. Проверяем: $1 + 1 - 2 = 0$, всё допустимо.

Градиентный шаг решил увеличить только a_1 с 1 до 1.5:

$$a = (1.5,\ 1,\ 2) \quad \Rightarrow \quad 1.5 + 1 - 2 = 0.5 \neq 0$$

Условие нарушено, точка стала недопустимой. Если сдвинуть сразу все три a_i каждое по своему градиенту, сумма почти наверняка тоже не останется нулём.

Вывод: менять одно число нельзя, любое такое изменение ломает равенство.

Выход: менять сразу два числа. Если a_i изменилось, второе число a_j надо подправить так, чтобы сумма $a_i y_i + a_j y_j$ осталась прежней. Для нашего примера есть два варианта.

Пара точек с разными метками $(1,\ 3)$: $y_1 = +1$, $y_3 = -1$. Увеличили a_1 на 0.5, значит a_3 тоже надо **увеличить** на 0.5:

$$a = (1.5,\ 1,\ 2.5) \quad \Rightarrow \quad 1.5 + 1 - 2.5 = 0 \ \checkmark$$

Пара точек с одинаковыми метками $(1,\,2)$: $y_1 = y_2 = +1$. Увеличили a_1 на 0.5, значит a_2 надо **уменьшить** на 0.5:

$$a = (1.5,\ 0.5,\ 2) \quad \Rightarrow \quad 1.5 + 0.5 - 2 = 0 \ \checkmark$$

Правило запоминать проще через изменения: $\Delta a_i\, y_i + \Delta a_j\, y_j = 0$.

Это и есть идея метода **SMO**: каждый раз берём пару точек, находим для них лучшие значения и идём дальше. Условие сохраняется, если сумма $a_i y_i + a_j y_j$ не меняется. Поэтому, как только мы нашли новое a_j, новое a_i определяется само: одно число выбираем свободно, второе подбирается автоматически. Задача по паре сводится к одной переменной, а её решить просто.

3.2. Один шаг по паре точек $(i,\ j)$

Нам понадобятся три величины.

Ошибка точки k — насколько текущая оценка модели отличается от метки:

$$E_k = f(x_k) - y_k, \qquad f(x_k) = \sum_t a_t y_t\,(x_t \cdot x_k) + b$$

Здесь $f(x_k)$ — оценка точки k при текущих a и b. Откуда такая формула: в обычной оценке $f(x_k) = \mathbf{w} \cdot x_k + b$ подставим вместо $\mathbf{w}$ его выражение из шага 2.4, $\mathbf{w} = \sum_t a_t y_t x_t$, в скобках:

$$f(x_k) = \Big(\sum_t a_t y_t x_t\Big) \cdot x_k + b$$

Скалярное произведение умножает x_k на каждое слагаемое суммы, как $(A_1 + A_2) \cdot x = A_1 \cdot x + A_2 \cdot x$. Поэтому x_k заходит внутрь суммы:

$$f(x_k) = \sum_t a_t y_t\,(x_t \cdot x_k) + b$$

Так оценка считается без самого $\mathbf{w}$, только через a_t, y_t и скалярные произведения точек.

Знаменатель шага — квадрат расстояния между точками. Квадрат длины вектора — это его скалярное произведение с самим собой, а расстояние между x_i и x_j — длина вектора $x_i - x_j$:

$$\eta = \|x_i - x_j\|^2 = (x_i - x_j) \cdot (x_i - x_j) = x_i \cdot x_i + x_j \cdot x_j - 2\,x_i \cdot x_j$$

Скобки раскрыты как $(a-b)^2 = a^2 - 2ab + b^2$. Пример: $x_i = (1, 2)$, $x_j = (4, 6)$. Через формулу: $5 + 52 - 2 \cdot 16 = 25$. Напрямую: $x_i - x_j = (-3, -4)$, квадрат длины $9 + 16 = 25$.

Так записано специально: в dual точки входят только через скалярные произведения, и потом $x_i \cdot x_j$ можно заменить на ядро.

Как η влияет на шаг. Он стоит в знаменателе:

$$\text{шаг} \sim \frac{\text{на сколько хотим сдвинуться}}{\eta}$$

Чем дальше точки друг от друга, тем η больше и шаг **меньше**. Для расстояния 5 получаем $\eta = 25$, для расстояния 1 получаем $\eta = 1$, и шаг получается в 25 раз крупнее.

Смысл: η показывает, насколько круто «изгибается» парабола, по которой ищем лучшее значение. Изгиб сильный, значит минимум рядом, и далеко прыгать нельзя, иначе проскочим. Изгиб слабый, парабола пологая, и можно прыгать дальше.

Почему расстояние связано с изгибом. Если точки далеко друг от друга, то даже маленький сдвиг t сильно двигает $\mathbf{w}$ (на t·расстояние), а значит быстро меняет целевую функцию. Парабола крутая, узкая, оптимум близко, и надо шагать осторожно. Если точки близко, тот же сдвиг t почти не двигает $\mathbf{w}$, парабола пологая, оптимум далеко, и можно шагать крупно.

Если точки совпадают, $\eta = 0$: парабола превращается в прямую, делить на ноль нельзя, и такую пару пропускают.

η — только знаменатель. Размер шага зависит ещё и от числителя, то есть от разницы ошибок $E_i - E_j$: если ошибки почти одинаковые, шаг маленький независимо от η.

Новое a_j:

$$a_j^{\text{новое}} = a_j + \frac{y_j\,(E_i - E_j)}{\eta}$$

Когда перекладывать вес имеет смысл. Вес на точке — это «давление», которое подталкивает оценку этой точки к её метке. Условие $\sum a_i y_i = 0$ фиксирует общий бюджет весов, поэтому шаг SMO — это перекладка веса между двумя точками. Возьмём две точки:

- Обе одинаково недовольны (ошибки одинаковые). Отдашь вес одной, чтобы помочь другой, и первой станет хуже ровно настолько, насколько второй лучше. Выигрыша нет, шаг равен нулю.
- У одной ошибка большая, у другой маленькая. Тогда вес выгодно переложить к той, кому он нужнее: недовольной точке станет заметно лучше, а довольная почти не пострадает. Чем сильнее разница ошибок, тем выгоднее перекладка и тем крупнее шаг.

Затем a_j нужно **обрезать**, чтобы оба числа остались ≥ 0: формула выше про $a \geq 0$ ничего не знает и может выдать, например, отрицательное значение. Справа в таблице стоят **старые** a_i и a_j, слева — новое a_j:

Метки $y_i,\ y_j$	**допустимо для** $a_j^{\text{новое}}$
одинаковые	$0 \leq a_j^{\text{новое}} \leq a_i + a_j$
разные	$a_j^{\text{новое}} \geq \max(0,\ a_j - a_i)$ (сверху ограничения нет)

Откуда границы. При одинаковых метках сумма $a_i + a_j$ не меняется, поэтому одно число может вырасти только за счёт другого, и a_j не может быть больше всей суммы, иначе a_i уйдёт в минус. При разных метках не меняется разность $a_i - a_j$: оба числа растут или убывают вместе, поэтому сверху ограничения нет, а снизу a_j нельзя опускать так, чтобы a_i стало отрицательным.

Новое a_i (чтобы сохранилось $\sum a_i y_i = 0$):

$$a_i^{\text{новое}} = a_i + y_i\, y_j \left(a_j - a_j^{\text{новое}}\right)$$

Новое b**.** После изменения a пересчитываем b из условия, что у опорной точки оценка равна ± 1:

$$b_1 = b - E_i - y_i \left(a_i^{\text{нов}} - a_i\right)(x_i \cdot x_i) - y_j \left(a_j^{\text{нов}} - a_j\right)(x_i \cdot x_j)$$

$$b_2 = b - E_j - y_i \left(a_i^{\text{нов}} - a_i\right)(x_i \cdot x_j) - y_j \left(a_j^{\text{нов}} - a_j\right)(x_j \cdot x_j)$$

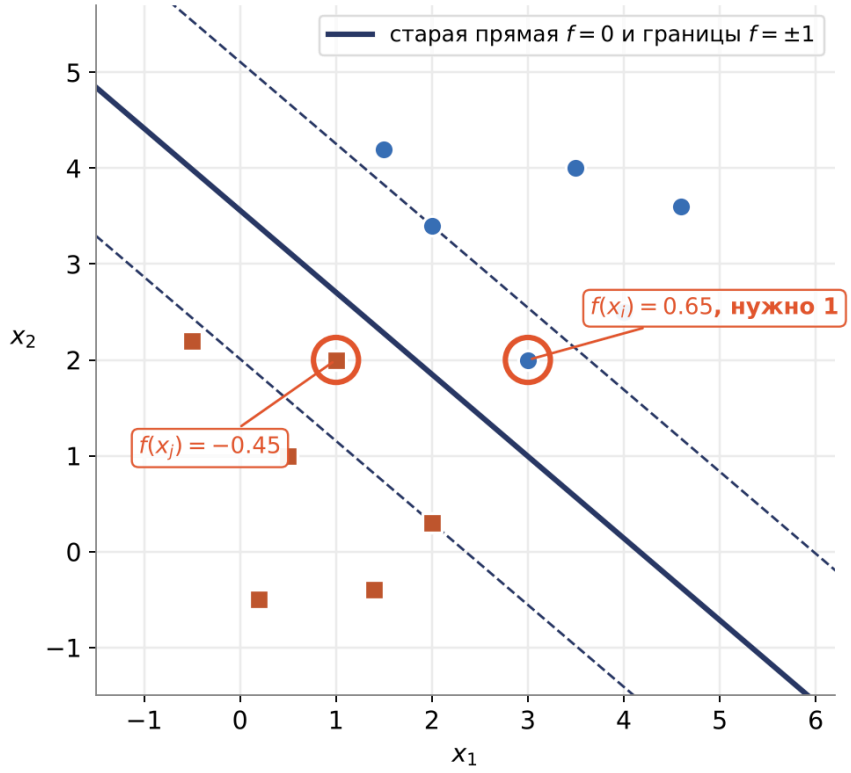
Берём $b = b_1$, если $a_i^{\text{нов}} > 0$; иначе $b = b_2$, если $a_j^{\text{нов}} > 0$; иначе среднее $(b_1 + b_2)/2$.

Что происходит с b **на примере.** Берём точки $x_i = (3,\ 2)$ (метка $+1$) и $x_j = (1,\ 2)$ (метка -1) из набора из этого раздела. Перед шагом: $\mathbf{w} = (0.55,\ 0.65)$, $b = -2.30$.

Идея простая: сначала веса a **наклоняют** линию (меняют её поворот), а потом b **подгоняет** её: сдвигает параллельно, не меняя наклон, чтобы опорные точки снова встали ровно на границы зазора. Старую ошибку E_i запоминаем до шага, потому что она показывает, насколько линия уехала.

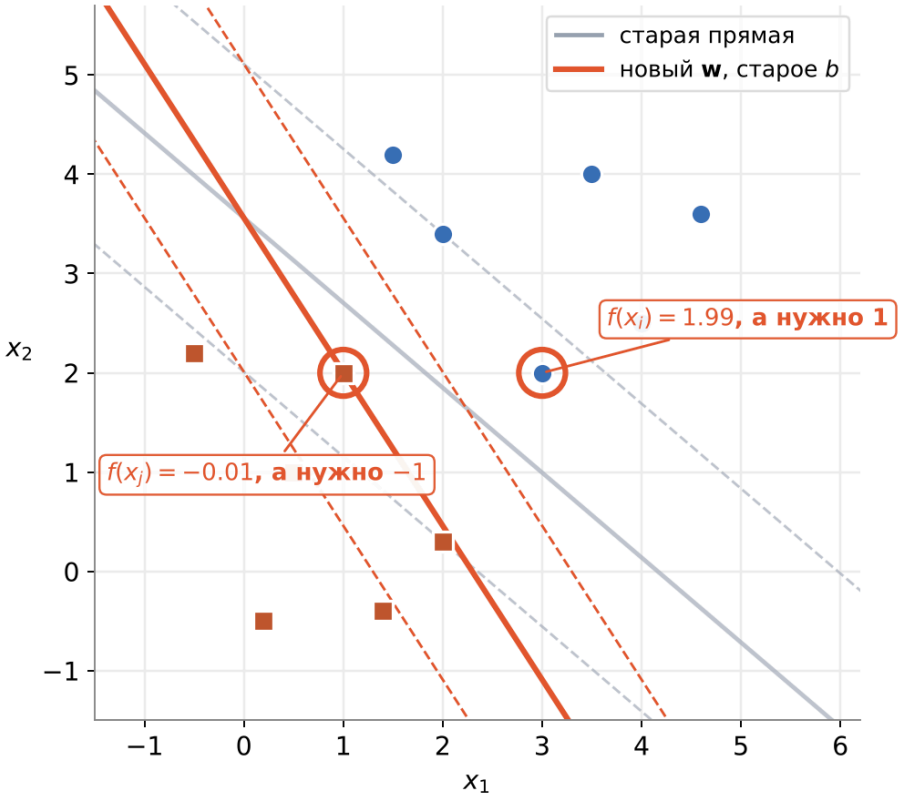
Шаг 1. До шага. Оценка точки i равна $f(x_i) = 0.65$, а опорной точке нужно $+1$. Ошибка $E_i = 0.65 - 1 = -0.35$.

Шаг 1. До шага: оценка точки i равна 0.65, а должна быть 1



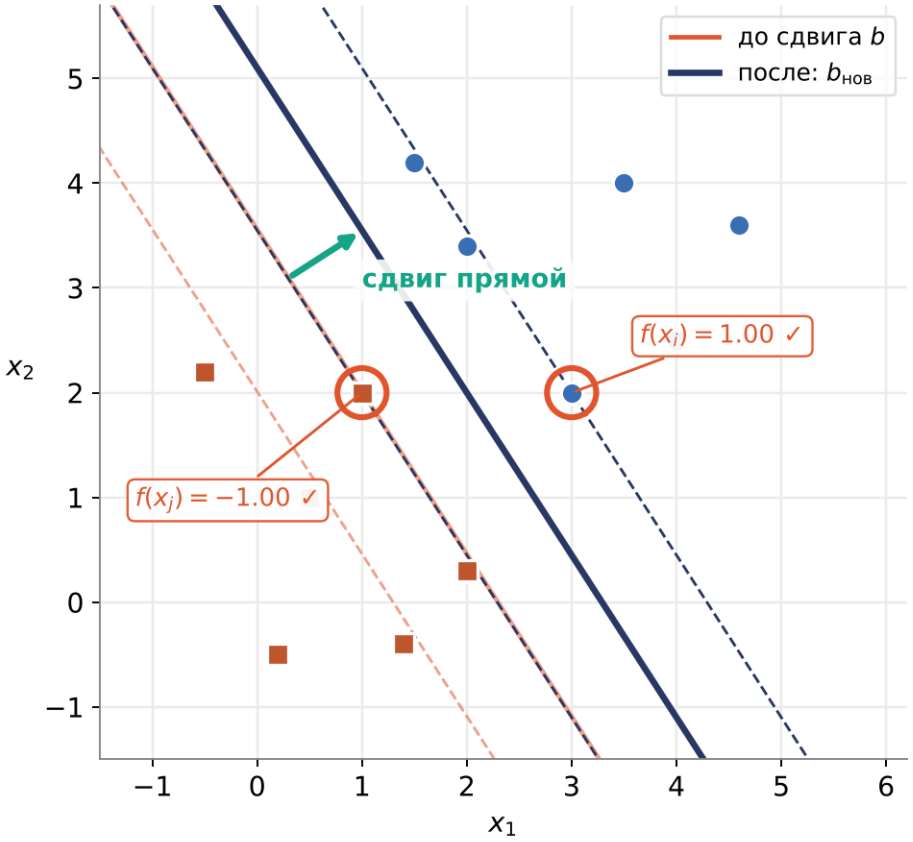
Шаг 2. Меняем веса. Пара a_i, a_j выросла с 0.28 до 0.50, и $\mathbf{w}$ стал $(1.00,\ 0.65)$. Прямая повернулась, а b пока старое. Оценки обеих точек сползли: $f(x_i) = 1.99$ (нужно 1), $f(x_j) = -0.01$ (нужно -1).

Шаг 2. Веса изменились, b ещё старое: обе точки сползли



Шаг 3. Подкручиваем b. По формуле $b_1 = -2.30 - (-0.35) - 1 \cdot 0.224 \cdot 13 - (-1) \cdot 0.224 \cdot 7 \approx -3.29$ (здесь $\Delta a = 0.224$, $x_i \cdot x_i = 13$, $x_i \cdot x_j = 7$). Новое b сдвинуло прямую параллельно самой себе, и обе точки встали ровно на границы: $f(x_i) = 1$, $f(x_j) = -1$.

Шаг 3. Сдвигаем b: обе точки встали ровно на границы



Поворот прямой делают веса, а b только двигает её параллельно, пока опорные точки не окажутся на границах.

3.3. Какие пары брать

Пару выбираем не случайно, а по условию KKT из шага 2.6.

- **Точка i.** Берём такую, у которой KKT нарушено. Для точки с запасом $m_i = y_i f(x_i)$ это значит: либо $m_i < 1$ (точка попала в зазор или на чужую сторону), либо $m_i > 1$ при $a_i > 0$ (дальняя точка зачем-то имеет ненулевой вес). Допуск ε нужен, чтобы не гоняться за ничтожными нарушениями.
- **Точка j.** Берём ту, у которой ошибка E_j сильнее всего отличается от E_i, то есть с наибольшим $|E_i - E_j|$. Если на этой паре ничего не изменилось, пробуем следующую.

3.4. Псевдокод

```
f(x_k) = сумма по t от ( a[t] * y[t] * (x[t]·x[k]) ) + b
E_k    = f(x_k) - y[k]
```

```
a = [0, ..., 0]
b = 0

повторять, пока что-то меняется:
    для каждой точки i:
        если точка i нарушает KKT:
            j = случайная точка, j != i

            eta     = x[i]·x[i] + x[j]·x[j] - 2 * x[i]·x[j]
            a_j_нов = a[j] + y[j] * (E_i - E_j) / eta

            если y[i] == y[j]:  low = 0,                  high = a[i] + a[j]
            иначе:              low = max(0, a[j]-a[i]),  high = бесконечность
            a_j_нов = обрезать a_j_нов до [low, high]

            a_i_нов = a[i] + y[i] * y[j] * (a[j] - a_j_нов)

            d_i = a_i_нов - a[i]
            d_j = a_j_нов - a[j]
            b1  = b - E_i - y[i]*d_i*(x[i]·x[i]) - y[j]*d_j*(x[i]·x[j])
            b2  = b - E_j - y[i]*d_i*(x[i]·x[j]) - y[j]*d_j*(x[j]·x[j])

            если a_i_нов > 0:        b = b1
            иначе если a_j_нов > 0:  b = b2
            иначе:                   b = (b1 + b2) / 2

            a[i] = a_i_нов
            a[j] = a_j_нов

w = сумма по i от ( a[i] * y[i] * x[i] )
```

Точка нарушает KKT, если $y_i E_i < -\varepsilon$, либо $y_i E_i > \varepsilon$ при $a_i > 0$ (раздел 3.3). Предсказание такое же, как в разделе 4.

3.5. Пример: две точки

Точки $x_1 = (1,\, 1)$ с меткой $+1$ и $x_2 = (-1,\, -1)$ с меткой -1. Старт: $a_1 = a_2 = 0$, $b = 0$.

Оценки сейчас $f(x_1) = f(x_2) = 0$, поэтому ошибки $E_1 = 0 - 1 = -1$ и $E_2 = 0 - (-1) = +1$. Запас первой точки $m_1 = y_1 E_1 = -1 < 0$: условие нарушено, берём пару $(1,\, 2)$.

- Скалярные произведения: $x_1 \cdot x_1 = 2$, $x_2 \cdot x_2 = 2$, $x_1 \cdot x_2 = -2$. Значит $\eta = 2 + 2 - 2 \cdot (-2) = 8$.
- Метки разные, поэтому нижняя граница $\max(0,\, a_2 - a_1) = 0$, верхней нет.

- $a_2^{\text{нов}} = 0 + \dfrac{(-1)\cdot(-1-1)}{8} = \dfrac{2}{8} = 0.25.$
- $a_1^{\text{нов}} = 0 + (+1)(-1)\,(0 - 0.25) = 0.25.$
- $b_1 = 0 - (-1) - 1 \cdot 0.25 \cdot 2 - (-1) \cdot 0.25 \cdot (-2) = 1 - 0.5 - 0.5 = 0$. Так как $a_1 > 0$, берём $b = 0$.

Проверка: $a_1 y_1 + a_2 y_2 = 0.25 - 0.25 = 0$. Вес $\mathbf{w} = 0.25 \cdot (1,\,1) - 0.25 \cdot (-1,\,-1) = (0.5,\,0.5)$. Оценка первой точки $\mathbf{w} \cdot x_1 + b = 1$, второй -1: обе точки лежат ровно на границе зазора, обе опорные. Условия KKT выполнены, второй проход ничего не изменит.

Для сравнения, из двойственной функции напрямую: $D(a) = 2a - 4a^2$ (при $a_1 = a_2 = a$), максимум при $a = \frac{1}{4}$. Тот же ответ.

---

4. Как вернуться к $\mathbf{w}$, b и предсказанию

Этот раздел дописан к конспекту: в нём то, чем заканчивается вывод.

1. Решаем двойственную задачу и находим все a_i.
2. Восстанавливаем вес: $\mathbf{w} = \sum_i a_i y_i x_i$.
3. Находим b из любой опорной точки s (у неё $a_s > 0$, значит $y_s(\mathbf{w} \cdot x_s + b) = 1$):

$$b = y_s - \mathbf{w} \cdot x_s$$

1. Предсказание для новой точки x:

$$\text{оценка} = \sum_i a_i y_i \,(x_i \cdot x) + b \qquad \text{класс} = \operatorname{sign}(\text{оценка})$$

5. Итог

1. Условие $y_i(\mathbf{w} \cdot x_i + b) \geq 1$ встраиваем в функцию с помощью множителей $a_i \geq 0$ (по одному на точку).
2. Меняем местами $\min$ и $\max$. Для нашей выпуклой задачи ответ не меняется ($p^* = d^*$).
3. Минимум по $\mathbf{w}$ и b берётся в явном виде: $\mathbf{w} = \sum a_i y_i x_i$ и $\sum a_i y_i = 0$.
4. Остаётся задача только про a: максимизировать $\sum a_i - \frac{1}{2}\sum\sum a_i a_j y_i y_j (x_i \cdot x_j)$ при $a_i \geq 0$ и $\sum a_i y_i = 0$.
5. Из-за KKT ненулевые a_i только у опорных точек, остальные точки в ответ не входят.
6. Данные входят только через $x_i \cdot x_j$, поэтому в dual можно использовать ядра.

Задачу про a решаем численно методом SMO: на каждом шаге берём пару точек, меняем сразу два числа a_i и a_j (раздел 3).