- Урок в прозе: https://proproprogs.ru/ml/ml-lineynaya-model-ponyatie-pereobucheniya (https://proproprogs.ru/ml/ml-lineynaya-model-ponyatie-pereobucheniya)
- Телеграм-канал: https://t.me/selfedu_sb (https://t.me/selfedu_sb)
- Телеграм-чат: https://t.me/machine_learning_selfedu (https://t.me/machine_learning_selfedu)

- К. В. Воронцов: https://ya-r.ru/2020/05/07/vorontsov-kurs-mashinnoe-obuchenie-2019-shkola-analiza-dannyh/ (https://ya-r.ru/2020/05/07/vorontsov-kurs-mashinnoe-obuchenie-2019-shkola-analiza-dannyh/)
- Лекции К. В. Воронцова: https://www.youtube.com/watch?v=SZkrxWhI5qM&list=PLJOzdkh8T5krxc4HsHbB8g8f0hu7973fK (https://www.youtube.com/watch?v=SZkrxWhI5qM&list=PLJOzdkh8T5krxc4HsHbB8g8f0hu7973fK)
- Лекции С. Николенко: https://www.youtube.com/watch?v=BPcicsBuRdc&list=PL-_cKNuVAYAWXoVzVEDCT-usTEBHUf4AF (https://www.youtube.com/watch?v=BPcicsBuRdc&list=PL-_cKNuVAYAWXoVzVEDCT-usTEBHUf4AF)
- Курс по Python: https://stepik.org/course/100707/ (https://stepik.org/course/100707/)
- Курс по Python ООП: https://stepik.org/course/116336/ (https://stepik.org/course/116336/)
- Курс по основам теории вероятностей: https://stepik.org/course/136024/ (https://stepik.org/course/136024/)
- Курс по NumPy: YouTube (https://www.youtube.com/playlist?list=PLA0M1Bcd0w8zmegfAUfFMiACPKfdW4ifD) | RuTube (https://rutube.ru/plst/535156)

Линейная модель. Понятие переобучения

На предыдущем занятии мы увидели, что задачи машинного обучения – это задачи оптимизаци в частности минимизации эмпирического риска:

$$Q(a, X^l) = \frac{1}{l}\sum_{i=1}^{l} L(a, x_i)$$

зависящего, в общем виде, от модели $a(x)$ и вида функции потерь $L(a, x)$. То есть, нам нужно выбрать такую модель, чтобы функционал принимал наименьшее значение на обучающей выборке. Математически это можно записать так:

$$\mu(X^l) = \arg\min_{a \in A} Q(a, X^l)$$

Здесь $\mu(X^l)$ - найденная модель на этапе обучения по всем возможным моделям $a \in A$; argmir – определяет значение аргумента, при котором функция принимает наименьшее значение.

В случае параметрических моделей $a(x) = g(x, \theta)$ это выражение может быть записано относительно вектора параметров θ:

$$\mu(X^l) = \arg\min_{\theta} Q(a, X^l)$$

После обучения мы принимаем $a = \mu(X^l)$ и используем найденную зависимость в продакшене (при практической реализации).

Вот так математически можно кратко записать то, о чем мы говорили на предыдущем занятии. Давайте снова вернемся к нашему простейшему примеру – методу наименьших квадратов. Здес у нас данные формируются по закону:

$$y_i = kx_i + b + \varepsilon_i,\ i = 1, 2, \dots$$

где $\{\varepsilon_i\}$ - по прежнему гауссовский шум с нулевым средним. Для такой задачи оптимальная модель имеет вид линейной функции:

$$a(x) = \hat{k}x + \hat{b}$$

Неизвестные параметры k, b я обозначил с крышечкой, что означает, что мы не можем их точно определить (всегда будет погрешность, неточность). Так вот, эту же модель можно записать и в таком виде:

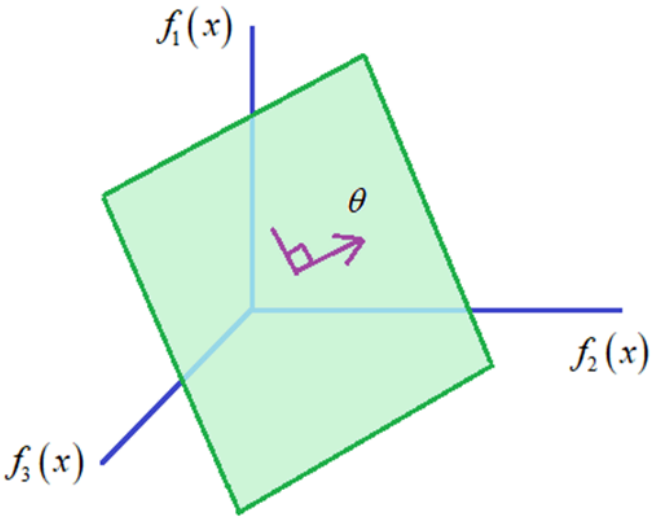
$$a(x) = \theta_1 \cdot f_1(x) + \theta_2 \cdot f_2(x)$$

если выбрать: $\theta_1 = \hat{k},\ \theta_2 = \hat{b}$ и $f_1(x) = x,\ f_2(x) = 1$. Модели, которые представляют собой линейную комбинацию признаков с некоторыми настраиваемыми параметрами (весами), называются **линейными**.

В общем случае любую линейную модель можно представить в виде следующей суммы:

$$a(x) = \sum_{i=1}^{n} \theta_i \cdot f_i(x)$$

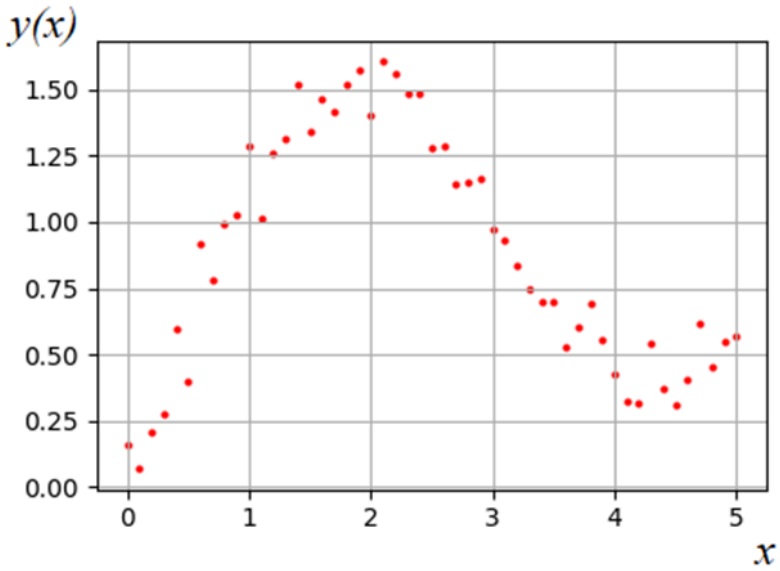
Почему такая модель считается линейной? Если мы перейдем в пространство признаков $\{f_i(x)$ то в нем модель $a(x)$ будет описывать гиперплоскость, ориентация которой определяется вектором параметров $\theta = [\theta_1, \dots, \theta_n]^T$:



Такие модели достаточно просты, хорошо изучены и нередко приводят к приемлемым результатам. Мы с вами вначале подробно изучим работу этих моделей.

Давайте для примера рассмотрим задачу линейной регрессии, в которой будем строить аппроксимацию эмпирических данных, сформированных по правилу:

$$y(x) = sin(x) + 0,3x + \varepsilon(x),\ x \in [0; 5]$$



Строго говоря, мы здесь имеем одномерную величину x, по которой нужно спрогнозировать выходное значение $y(x)$. То есть, исходные измерения – это x, а целевые выходные – это $y(x)$. Однако, если строить линейную модель по одному признаку x в виде:

$$a(x) = \theta_1 \cdot x$$

то, как вы понимаете, мы очень грубо будем описывать изменения представленных (на графике) точек. Здесь явно нелинейная зависимость $y(x)$. Поэтому, чтобы оставаться в рамках линейной модели при решении подобных задач, мы расширим признаковое пространство следующими преобразованиями:

$$f_0(x) = 1$$

$$f_1(x) = x$$
$$f_2(x) = x^2$$
$$\dots$$
$$f_n(x) = x^n$$

Причем, преобразования, как правило, выбираются так, чтобы признаки были линейно независимыми. Иначе, один признак просто сведется к другому. Например, пара преобразовани

$$f_1(x) = x;\ f_2(x) = x + 5$$

это, фактически, один и тот же признак, т.к. значение +5 с успехом может быть добавлено признаком

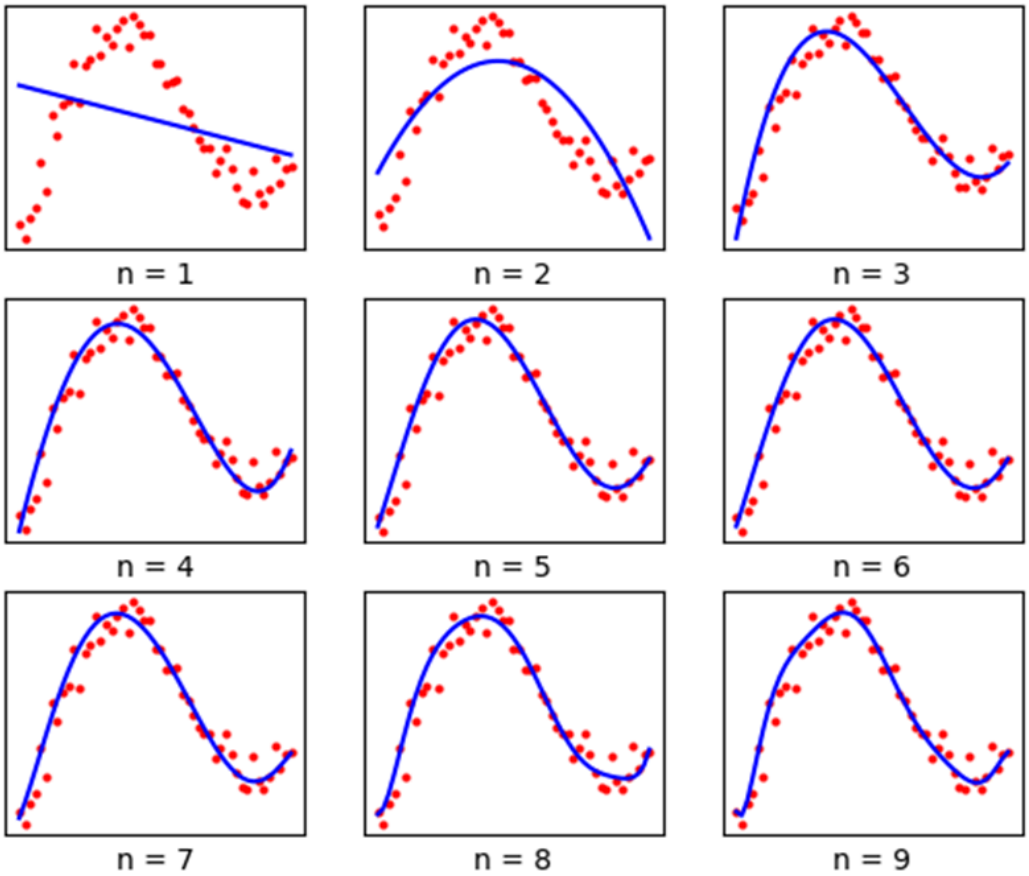
$$5 \cdot f_0(x) = 5 \cdot 1 = 5$$

Вот на это следует обращать внимание при формировании нового признакового пространства – оно должно быть информативным, а не просто дублировать данные.

Итак, расширение пространства признаков с помощью функциональных преобразований – это нормальная практика. В результате, наша линейная модель будет вычислять выходные значени в виде полинома:

$$a(x) = 1 \cdot \theta_1 + x \cdot \theta_2 + x^2 \cdot \theta_3 + \dots + x^n \cdot \theta_{n+1}$$

где $[\theta_1, \dots, \theta_{n+1}]^T$ - вектор весовых коэффициентов, которые определяются по входным эмпирическим данным (обучающей выборке). То есть, для каждого $x \in [0; 5]$ мы будем вычислять $a(x)$ - это и будет прогнозом величины $y(x)$. В результате, если взять полином перво степени ($n = 1 \rightarrow a(x) = \theta_1 + \theta_2 \cdot x$), то получим аппроксимацию точек линейной функцией:



Увеличивая порядок полинома, мы все точнее и точнее будем описывать экспериментальные зависимости. Казалось бы, мы с вами только что нашли универсальное решения для задачи регрессии (да и классификацию тоже можно делать по этому принципу)? Берем полином сколь угодно большой степени и описываем им эмпирические данные с нужной точностью. Но, увы, природа так просто не сдает своих позиций и в полиномах с высокими степенями кроется один неприятный момент. Давайте возьмем функцию вида:

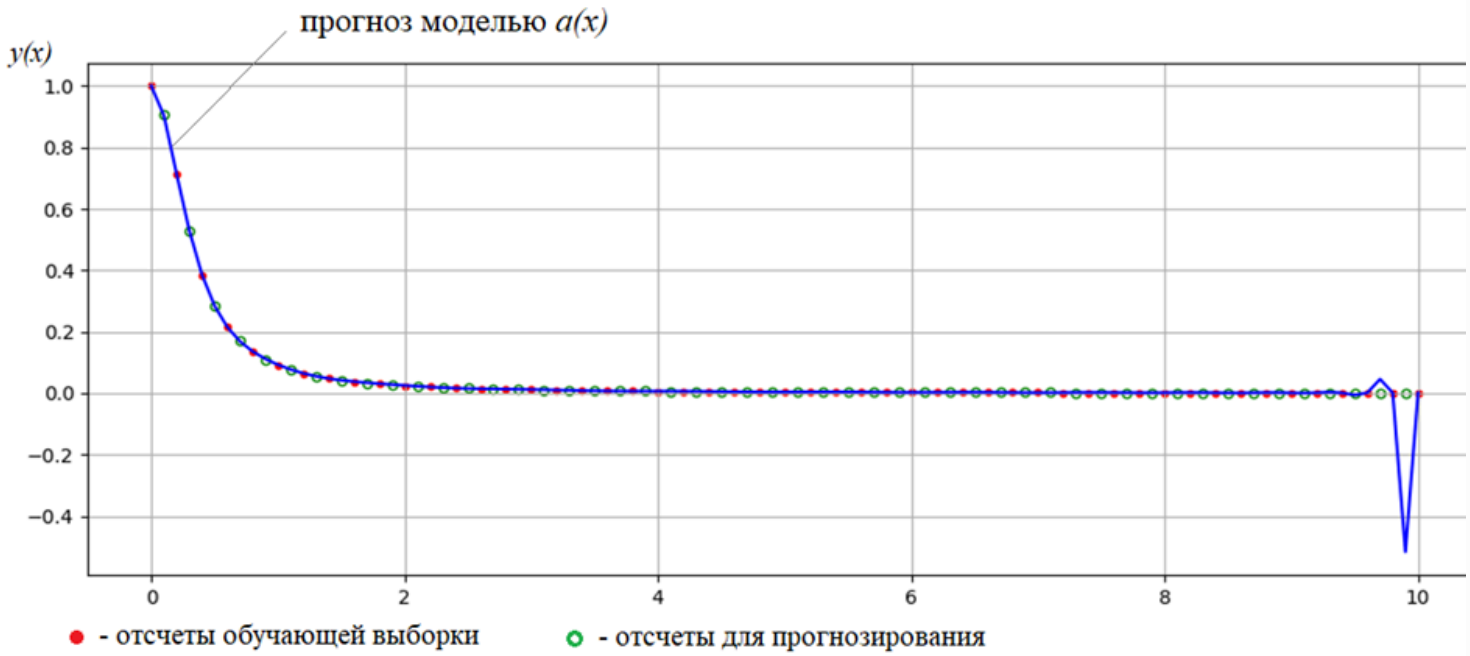
$$y(x) = \frac{1}{1 + 10x^2}, \; x \in [0; 10]$$

И будем ее приближать полиномом степени n = 54. Но коэффициенты полинома будем вычислят только по половине всех точек, взятых через отсчет. Тогда в другой половине точек полученная модель

$$a(x) = \sum_{i=0}^{54} \theta_i \cdot x^i$$

будет строить прогноз.

На рисунке ниже красными точками показаны значения функции, участвующие в расчетах параметров $\{\theta_i\}$, а зелеными – точки, в которых строится прогноз по полученной модели.



Как видите, при больших значениях x полином ведет себя совершенно непредсказуемым образом. Это известный факт, знакомый всем математикам. Применительно к нашей задаче, эт означает, что такая модель плохо будет строить прогнозы в новых, неизвестных ей точках. То есть, с одной стороны, полином высокой степени хорошо описывает точки обучающей выборки, но совершенно непригоден для построения прогнозов в новых точках.

А вот с полиномами меньших степеней таких проблем, как правило, нет. Я приведу еще один график, где покажу, как меняется значение эмпирического риска для двух моделей:

- $a_1(x)$ - вычисленная по всем точкам функции $y(x)$;
- $a_2(x)$ - вычисленная по половине точек, взятых через отсчет.

В результате, имеем два выражения для эмпирических рисков:

$$Q_1(a_1, X^l) = \frac{1}{l}\sum_{i=1}^{l}\big(a_1(x_i) - y(x_i)\big)^2$$
$$Q_2(a_2, X^l) = \frac{1}{l}\sum_{i=1}^{l}\big(a_2(x_i) - y(x_i)\big)^2$$

и их графики при разных степенях полиномов $n = 1, 2, \ldots, 64$:

